基于多因素分析的 NIPT 时点选择与胎儿异常判定的优化研究

摘要

无创产前检测（NIPT）是当前临床上应用广泛的一种产前筛查技术，其核心在于通过母体血液中的游离 DNA 判断胎儿健康状况。检测时点的选择对结果准确性至关重要；孕周、孕妇体重指数以及年龄等个体因素都会影响检测结果。因此, 我们通过数学建模对影响因素进行了分析，并提出了合理的检测时点选择方案与胎儿异常判定方案。

问题一聚焦于 Y 染色体浓度与其影响因素的研究。首先，我们对原始数据进行了清洗与可视化分析，使用 **Spearman 相关系数法**考察了 Y 染色体浓度与孕周、BMI、孕妇年龄之间的相关关系。随后，我们建立了一个**多元回归模型**，并加入了 **BMI 的二次项**以刻画其非线性效应。最后通过显著性检验验证模型有效。结果显示，孕周与 Y 浓度正相关，而 BMI 和年龄与其负相关。这一部分工作揭示了 Y 染色体浓度的影响因素，为后续检测时点的研究奠定基础。

问题二聚焦于 BMI 分组下的最优检测时点。针对不同 BMI 人群，我们采用**五分位分组法**，将孕妇分为 Q1 至 Q5 五组。随后，我们构建了一个**风险函数模型**，将“检测过早需要补检”和“检测过晚带来延迟”两类风险纳入统一框架。通过在合理孕周范围内搜索风险最小值，得到各组对应的最优检测时点。最后，为了检验结果的可靠性，我们引入了 **Bootstrap 重采样方法**，对分组结果进行多次模拟和不确定性评估。结果显示，5 组人群的最优检测周数分别是 13.9，16.2，16.6，14.0，17.3。

问题三聚焦于多因素和约束条件下的时点优化。我们沿用了第二问的**五分位分组法**。随后，我们额外引入孕妇的身高、体重和年龄等因素，并使用两类数据集：一类是**记录首次达标时间的样本**，用于构建**风险函数**；另一类是**包含全部检测记录的纵向数据**，用于计算**达标率**。在方法上，我们采用**“风险最小化”**与**“达标率约束”**相结合的思路：只有当某一检测时点的达标率超过设定阈值时，才在候选范围内寻找风险最低的周数。最后，我们同样通过 **Bootstrap 方法**检验结果的稳健性。该方法在保证检测成功率的前提下兼顾了早检和风险控制。结果显示，5 组人群的最优检测周数分别是 16.8，19.0，20.3，16.3，23.5。

问题四聚焦于女胎异常判定模型的构建。我们选取了孕妇年龄、孕周、测序质量指标以及 13、18、21 号染色体和 X 染色体的特征值，建立了 **Logistic 回归模型**。随后，我们利用 **Hosmer–Lemeshow 检验**验证了模型的拟合度。为进一步确保稳健性，我们还采用 **MLPClassifier 神经网络方法**进行交叉验证，比较两种方法的结果。验证表明，统计模型与机器学习模型在关键特征和判定趋势上保持一致，说明我们建立的女胎异常判定框架具有可靠性和可解释性。

研究结论显示，通过多种统计与机器学习方法，能系统解决 NIPT 检测时点选择与胎儿异常判定的问题。本研究提出的建模框架不仅具有统计学合理性，也兼顾了临床实际需求，为优化产前检测流程、提升筛查准确性提供了重要的参考依据。

关键字: 检测时点　胎儿异常判定　Spearman 相关系数　多元回归模型　风险函数模型　Bootstrap 重采样方法　Logistic 回归模型

目录

一、问题重述 **4**

1.1 问题背景 4

1.2 问题提出 4

二、问题分析 **4**

三、模型假设 **5**

四、符号说明 **6**

五、数据处理和可视化 **6**

5.1 数据清洗 6

5.2 数据可视化 6

5.3 数据可视化分析 8

六、问题一模型建立与求解 **9**

6.1 问题一的求解思路 9

6.2 问题一的模型搭建 11

6.3 问题一的求解结果 11

6.3.1 回归模型结果 11

6.3.2 F 检验结果 12

6.3.3 t 检验 12

七、问题二模型建立与求解 **13**

7.1 BMI 分组 13

7.2 风险函数构建 14

7.3 最优 NIPT 检测周数的确定 14

7.4 Bootstrap 误差分析 15

7.4.1 分组数据准备 15

7.4.2 风险函数与基线最优周计算 16

7.4.3 Bootstrap 重采样 16

7.4.4 不确定性区间计算 16

7.5 分析结果 16

八、问题三模型建立与求解 **17**

8.1 研究动机与总体思路 17

8.2 数据、分组与预处理 18
8.3 建模方法 19
8.4 求解结果 19
8.5 讨论与建议 21
8.6 小结 21
九、问题四模型建立与求解 **21**
9.1 数据与变量 22
9.2 模型设定与概率方程 22
9.3 估计结果与解释 22
9.4 模型拟合优度检验 23
9.5 讨论与结论 24
9.6 补充：基于神经网络的女胎异常判定模型验证 24
9.6.1 模型构建概要 24
9.6.2 关键验证结果 25
十、总结 **25**
附录 A 孕妇 BMI 与检测孕期的关系 **27**
附录 B Y 染色体浓度与检测孕期的关系 **27**
附录 C 问题一代码 **27**
附录 D 问题二代码 **31**
附录 E 问题三代码 **36**
附录 F 问题四代码 **40**

一、 问题重述

1.1 问题背景

NIPT（无创产前检测）是一种通过采集母体血液检测胎儿游离 DNA 片段以确定胎儿健康状况的技术，在产前检测中至关重要。临床中，胎儿是否患唐氏综合征等典型病症由特定染色体浓度是否异常决定，且检测准确性与胎儿性染色体浓度相关。同时，检测时点选择需考虑孕周和孕妇身体质量指数（BMI）等因素，不同孕妇个体差异大，若采用简单分组和统一检测时点，会影响准确性，还可能因检测不及时增加胎儿不健康带来的潜在风险。为优化 NIPT 检测，需深入研究各类孕妇群体合适的检测时点及相关影响因素，故开展本次数学建模研究。

1.2 问题提出

问题一：分析胎儿 Y 染色体浓度与孕妇孕周数、BMI 等指标的相关特性，构建关系模型并验证。

问题二：鉴于 BMI 是男胎孕妇胎儿 Y 染色体浓度最早达标时间的主要因素，对男胎孕妇 BMI 合理分组，给出每组 BMI 区间和最佳 NIPT 时点，同时分析检测误差对结果的影响。

问题三：综合考虑胎儿 Y 染色体浓度受身高、体重、年龄等多种因素影响，依据男胎孕妇 BMI，给出合理分组及每组最佳 NIPT 时点以最小化孕妇潜在风险，并分析检测误差的影响。

问题四：以女胎孕妇 21 号、18 号和 13 号染色体非整倍体携带判定为重点，综合考虑 X 染色体及相关染色体的 Z 值、GC 含量、读段数及比例、BMI 等因素，给出女胎异常的判定方法。

二、 问题分析

问题一: 旨在分析胎儿 Y 染色体浓度与孕妇孕周数、BMI 等指标的相关特性并构建关系模型，同时检验模型显著性。分析过程需分三步：首先预处理数据，筛选男胎样本、处理缺失与异常值，对连续变量做描述性统计；其次通过 Spearman 系数分析变量相关性，判断孕周、BMI 与 Y 染色体浓度的关联方向，排除多重共线性；最后结合相关性结果选择线性或非线性模型，并通过 F 检验、t 检验，确保模型能可靠反映指标间真实关系。

问题二: 问题二核心是基于男胎孕妇 BMI 分组确定最佳 NIPT 时点并分析检测误差影响。首先需明确 BMI 是男胎 Y 染色体浓度最早达标时间（≥4%）的关键因素，且需平衡“检测过早补检”与“检测过晚增加风险”的矛盾，同时保证分组样本量均衡以确保结果可靠性。因此，我们可以通过五分位分组法对 BMI 合理划分，这样既符合高 BMI 孕妇需更晚检测以积累足够游离 DNA 的临床逻辑，又能避免组间样本量差异导致的偏差。随后再构建融合补检代价与延迟成本的风险函数，找到每组风险最小的最优检测周数；最后引入 Bootstrap 重采样法模拟抽样分布，验证结果稳健性。

问题三: 问题三是在问题二基础上，进一步纳入身高、体重、年龄等多因素影响，且需结合检测误差与 Y 染色体浓度达标比例约束确定最佳 NIPT 时点。我们需解决“风险最小化”与“达标率合格”的双重目标：一方面，利用首次达标孕周数据集构建风险函数，量化“过早失败”与

“过晚延迟”的综合风险；另一方面，通过全量纵向记录表计算记录级达标比例），设定合理达标阈值，筛选出满足达标要求的候选孕周后，再选风险最小值。最后，通过 Bootstrap 重采样验证多因素干扰下结果的稳健性。

问题四: 问题四聚焦女胎异常判定，核心是围绕 21 号、18 号、13 号染色体非整倍体结果，整合多维度因素构建判定模型。因女胎无 Y 染色体，需重点挖掘与染色体异常相关的测序质量指标（如 GC 含量、读段数、比对比例）、染色体特征指标（如 Z 值、X 染色体浓度）及孕妇基础指标（年龄、BMI、孕周）的关联；分析过程中先通过变量筛选排除无统计学意义的变量以简化模型，再采用 Logistic 回归构建二元异常判定模型，将连续变量与分类结果建立概率关联，最后通过 Hosmer–Lemeshow 检验验证模型拟合优度，确保实际异常数与期望异常数差异较小，同时补充神经网络方法交叉验证，进一步验证判定模型的稳健性。

综上，问题解决的流程如图1所示。

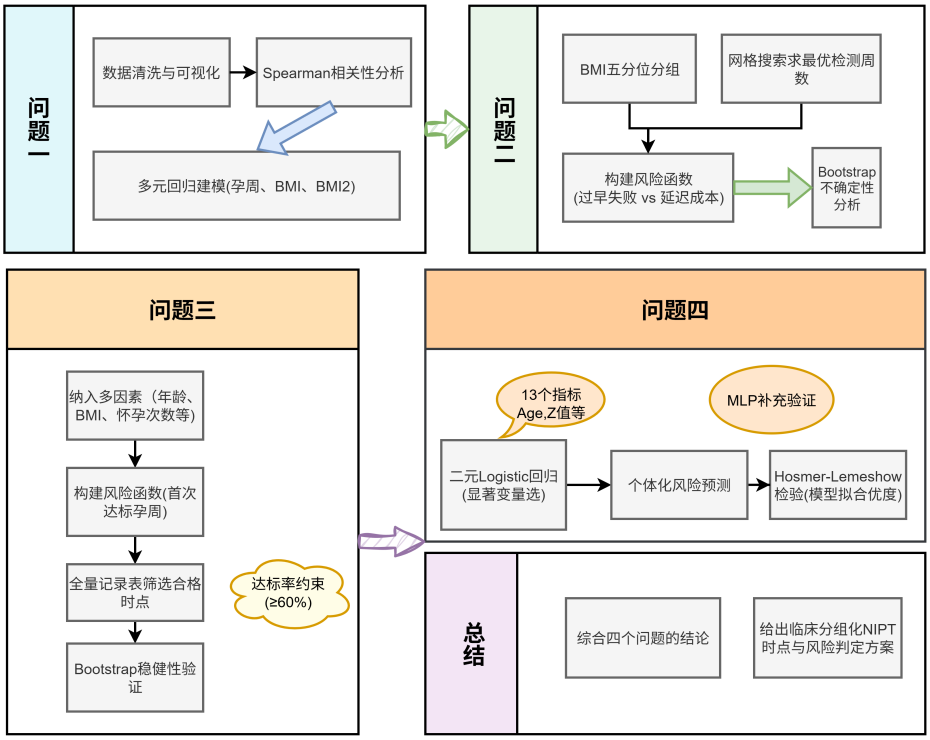


图 1　问题解决的流程

三、 模型假设

1. **多次检测数据独立性假设：**同一孕妇的多次采血 / 检测数据独立反映对应孕周的胎儿染色体真实浓度，无“前次检测影响后次结果”的系统性偏差。
2. **数据缺失与异常值假设：**原始数据中的缺失值为随机缺失，无系统性偏差。删除缺失值、剔除 GC 含量前 5% 分位数等异常值后，剩余数据能真实反映孕妇年龄、BMI、孕周及胎儿染色体浓度的实际特征。
3. **BMI 分组同质性假设：**采用五分位分组法划分 BMI 区间时，组内样本的 Y 染色体浓度达标

规律具有同质性，组间差异主要由 BMI 水平导致，与其他变量的混杂效应已通过数据分组减弱。

4. **临床延迟风险线性假设：**临床中“12 周以内发现异常风险低、13-27 周风险高、28 周以后风险极高”的分级标准，仅体现风险随孕周延迟的单调递增趋势；且在建模时，每延迟 1 周所提升的异常风险具有均匀性，即延迟成本的系数 C_{wait} 为常数，不随孕周所在区间发生阶段性变化。
5. **风险函数参数假设：**风险函数中补检代价 C_{fail}=1.0（单位补检成本）、延迟成本 C_{wait}=0.04（每推迟 1 周的时间成本）能合理量化临床中的“补检损失”与“延迟风险”。

四、 符号说明

表 1　符号说明

符号	说明	符号	说明
BMI_centered_sq	$(BMI - \bar{BMI})^2$	Age	孕妇年龄（岁）
Z21	21 号染色体的 Z 值	GA	检测孕周（周）
ZX	X 染色体的 Z 值	GC_genome	全基因组 GC 含量
Xfrac	X 染色体浓度	Reads	原始读段数
GC13	13 号染色体的 GC 含量	MapRate	参考基因组比对比例
GC18	18 号染色体的 GC 含量	Z13	13 号染色体的 Z 值
GC21	21 号染色体的 GC 含量	Z18	18 号染色体的 Z 值

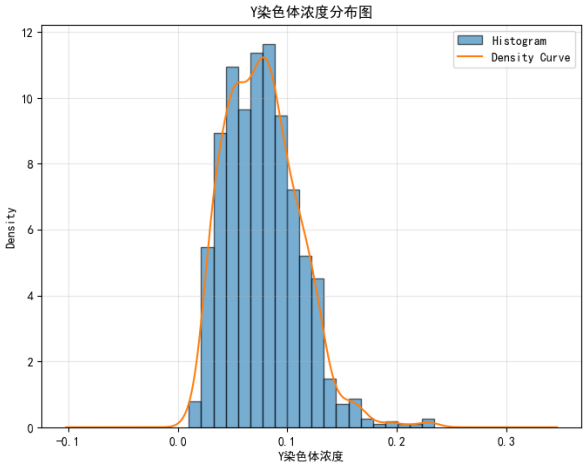
五、 数据处理和可视化

5.1 数据清洗

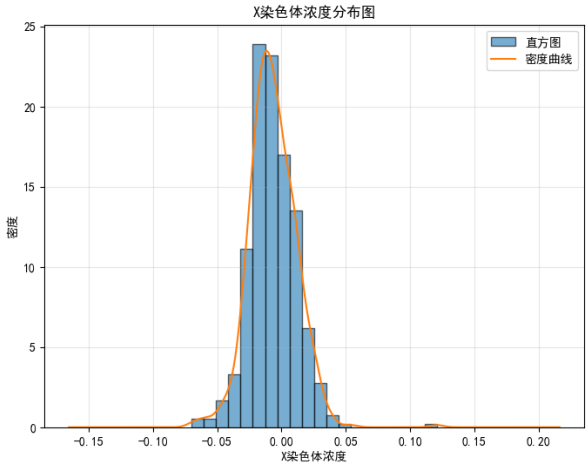
1. 检查并删除了数据中的缺失值。
2. 观察 Y 染色体浓度是否有低于 0 的情况。结果正常。
3. 根据 GC 含量，观察 GC 含量分布，发现全部在 60% 以下，大部分在 40% 以下，因此选择前 5% 分位数删除 [1]。
4. 将检测孕周改为天数，便于计算。

5.2 数据可视化

为了为了更好地观察孕妇和胎儿的各项因素，我们将一些数据进行可视化。这样我们能对孕妇和胎儿的情况进行初步了解。结果如图2、图3、图3所示

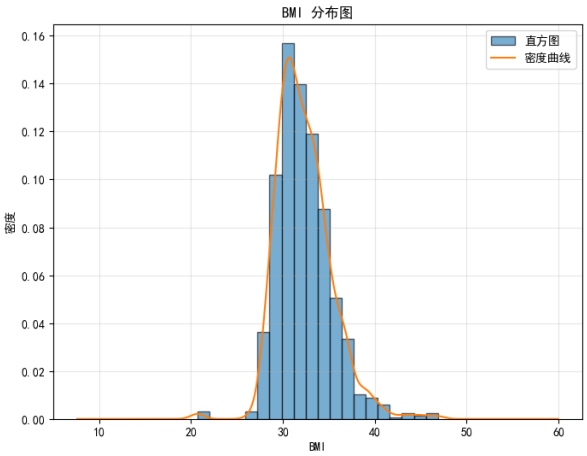


(a) Y 染色体浓度分布（男胎）

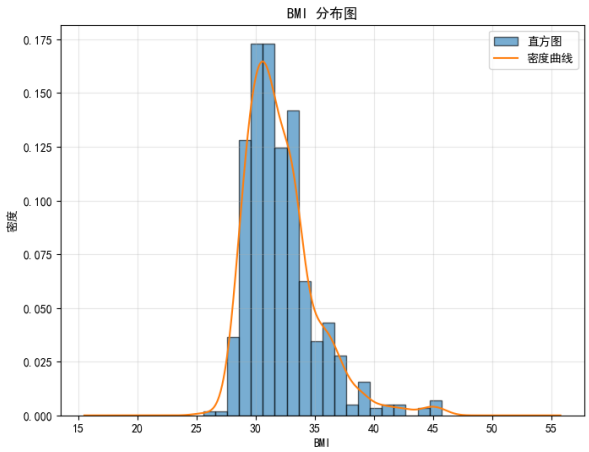


(b) X 染色体浓度分布（女胎）

图 2　染色体浓度分布

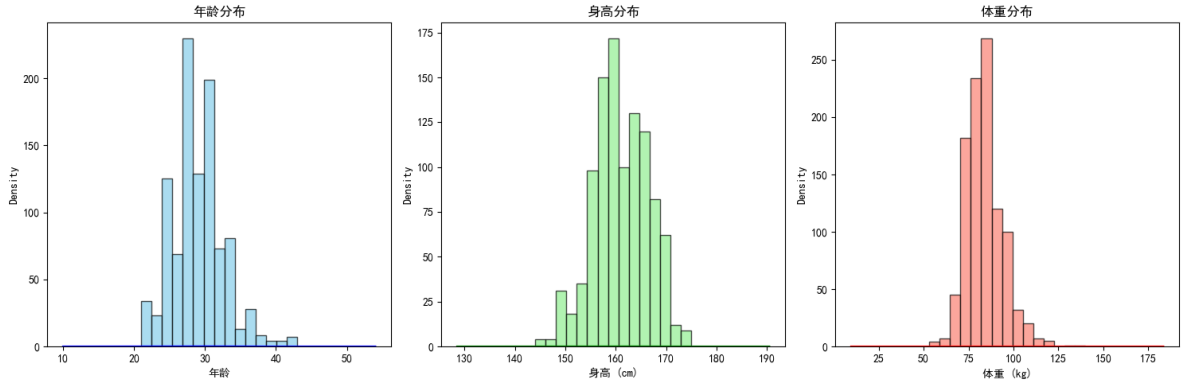


(a) BMI 分布图（男胎）

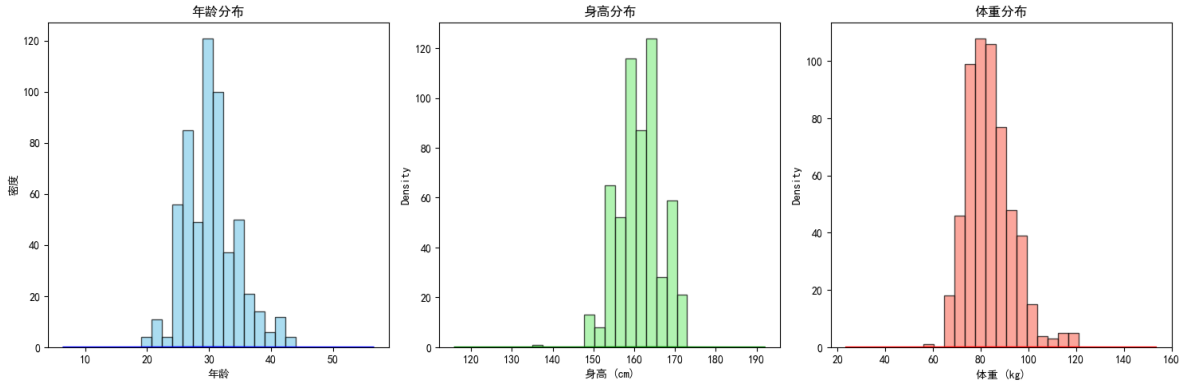


(b) BMI 分布图（女胎）

图 3　BMI 分布



(a) 年龄 & 身高 & 体重（男胎）



(b) 年龄 & 身高 & 体重（女胎）

图 4　年龄 & 身高 & 体重

5.3 数据可视化分析

- **染色体浓度：**如图2所示,X 染色体和 Y 染色体浓度都主要集中在一定区间内，曲线有明显的峰值，说明 X 染色体和 Y 染色体浓度在该峰值附近的样本数量较多，整体分布具有一定的集中性，这为后续分析染色体相关特性以及异常判定等问题提供了直观的分布参考。
- **BMI 浓度：**从图3,BMI 分布可视化图表来看，无论是男胎还是女胎对应的孕妇 BMI 分布，直方图与密度曲线都展现出明显的集中趋势。男胎孕妇的 BMI 主要集中在某一区间，女胎孕妇的 BMI 也有类似的集中分布特征，且两者的分布形态存在一定差异 [2]。这将为后续研究孕妇 BMI 对胎儿染色体浓度等方面的影响、进行 BMI 分组以确定最佳 NIPT 时点等问题提供直观的数据分布参考，有助于更好地把握不同胎儿性别下孕妇 BMI 的分布规律，为建立相关数学模型奠定基础。
- **年龄 & 身高 & 体重:** 从图4的年龄、身高与体重可视化图表来看，无论是男胎还是女胎对应的孕妇，年龄分布都呈现出明显的集中趋势，集中在某一特定年龄段；身高分布也较为集中，处于常见的身高区间范围内；体重分布同样有集中的特征。且男胎和女胎对应的孕妇在年龄、身高、体重的分布形态上存在一定差异，这些分布特征将为后续研究年龄、身高、体重等因素对胎儿 Y 染色体浓度达标时间等方面的影响提供直观的数据基础，有助于更好地把握不同胎儿性别下孕妇年龄、身高、体重的分布规律，为建立相关数学模型（如综合考虑这些因素确定最佳 NIPT 时点等）提供依据。

六、 问题一模型建立与求解

6.1 问题一的求解思路

首先，依据相关领域已发表的权威文献，我们从题目中选出了与 Y 染色体浓度存在潜在关联的指标作为核心研究变量。

随后，我们对样本数据进行了分布特征分析，分别绘制了孕妇 BMI 和检测孕周这两个指标与 Y 染色体浓度的分布图 (如5,6所示)。从数据分布形态，我们观察发现，孕妇 BMI 和检测孕周与 Y 染色体浓度之间并未呈现出典型的线性关联趋势，数据点的分布未沿某一固定直线规律变化，不符合线性关系的基本特征。

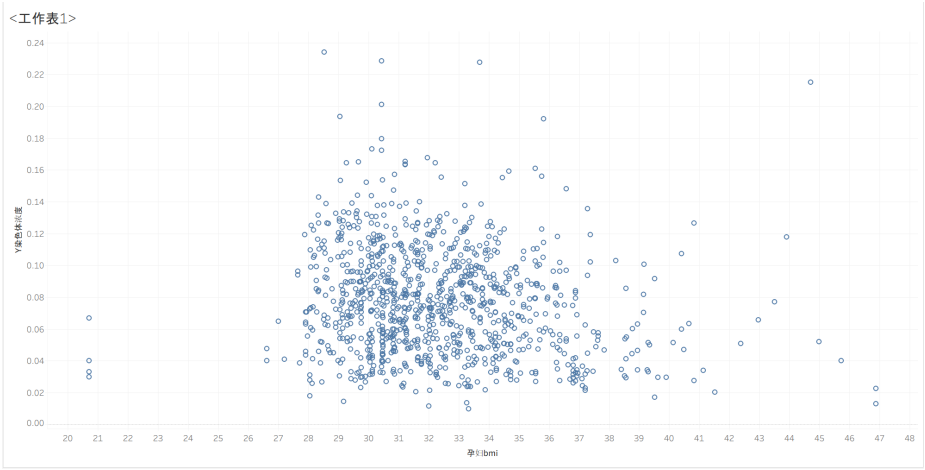


图 5　Y 染色体浓度与孕妇 BMI 关系

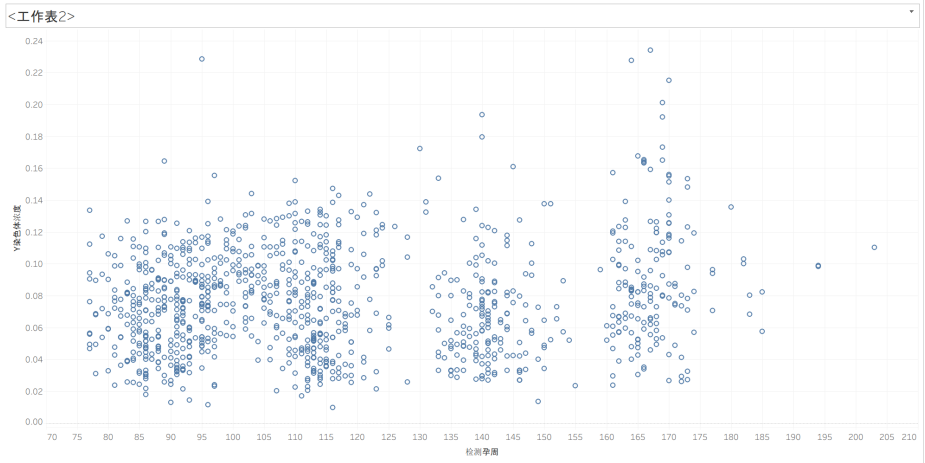


图 6　Y 染色体浓度与检测孕周关系

基于这一发现，我们首先排除了使用 Pearson 系数进行相关性分析的可能性。Pearson 系数是一种常用的线性相关系数，其核心假设是两个变量之间存在线性关系，并且要求数据近似服从正态分布。当变量间不存在线性关系时，Pearson 系数无法准确捕捉两者的关联程度，甚至可能得出错误的相关结论。

鉴于此，我们选择 Spearman 系数来探究孕妇 BMI 和检测孕周与 Y 染色体浓度之间的相关关系。Spearman 系数是一种非参数统计方法 [3]，其核心优势在于不依赖于变量的具体分布形态，也不要求变量间存在线性关系。该系数通过对两个变量的观测值进行等级排序，然后基于排序后的等级差来计算相关程度，能够有效捕捉变量间的单调相关关系。无论是线性还是非线性的单调关联，都能通过 Spearman 系数得到准确反映。

我们构建了 Spearman 相关性矩阵图, 如图7所示。该矩阵图能够将多变量间的两两相关关系以矩阵形式清晰呈现，通过系数数值与显著性标记的结合，可快速判断变量间相关关系的强弱与可靠性。可惜的是，尽管系数的显著性几乎为 0，但 Spearman 系数较低，可见 Spearman 揭示的相关性较弱。

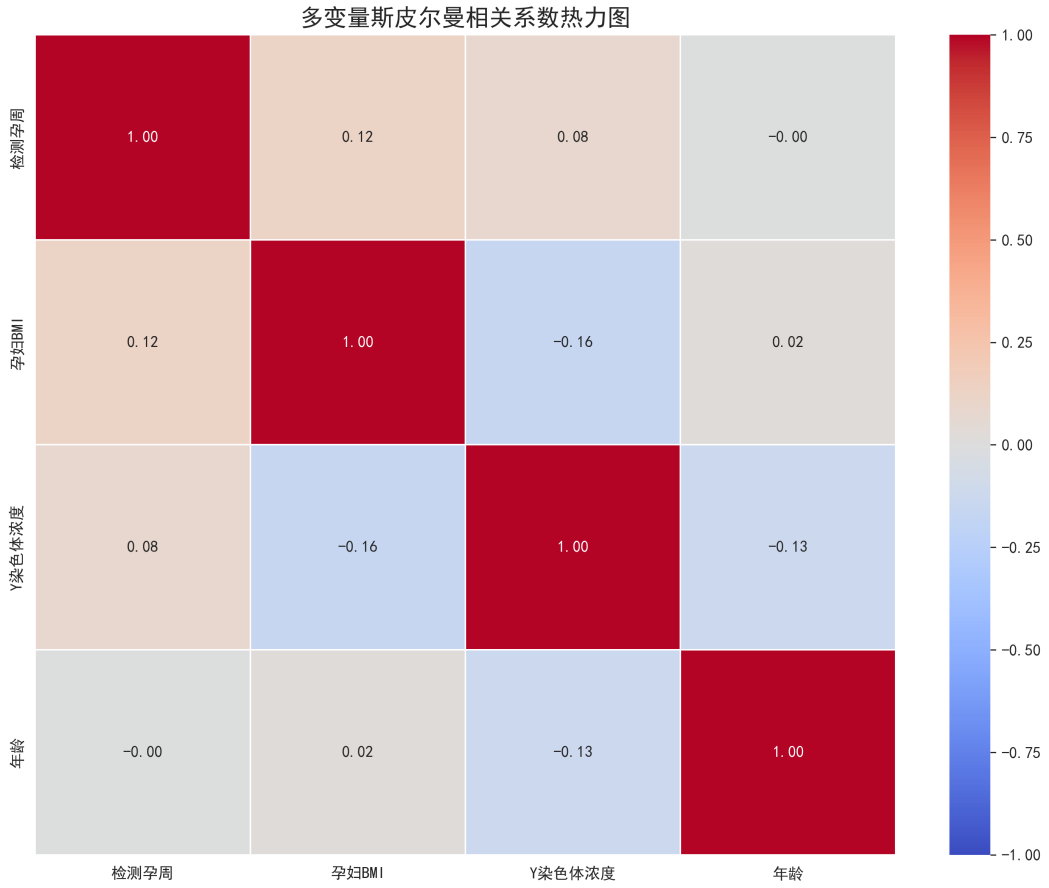


图 7　Spearman 系数

但是，我们能看出 Y 染色体浓度与孕妇 BMI 呈负相关。查阅医学文献得知，孕妇 BMI 较高时，往往体内脂肪含量较多。脂肪组织会分泌多种细胞因子和激素，这些物质会对母体的内分泌环境产生影响，进而干扰胎儿相关染色体物质的代谢与分布过程，使得胎儿 Y 染色体相关物质的合成、释放或在母体血液中的循环等环节受到抑制，最终导致 Y 染色体浓度降低。

同时，我们还看出 Y 染色体浓度与孕妇年龄呈负相关。从医学机制角度剖析，随着孕妇年龄增长，卵巢功能逐渐衰退，卵子质量也会有所下降。这会影响胚胎的正常发育进程，使得胎儿细胞中与 Y 染色体相关的物质合成与分泌受到一定限制。同时，年龄较大的孕妇，其自身的免疫系统和代谢调节能力也会发生变化，可能会对胎儿 Y 染色体相关物质进入母体血液的过程产

生阻碍作用，进而导致 Y 染色体相关物质在母体血液中的浓度随着孕妇年龄的增长而降低，呈现出负相关的关系。

最后，我们能看出 Y 染色体浓度与检测孕周呈正相关。原因是：随着孕周的不断增加，胎儿在母体内持续生长发育，其细胞分裂与增殖活动愈发活跃，会有更多携带 Y 染色体的细胞或相关遗传物质通过胎盘等途径进入母体血液循环系统。从而使母体血液中 Y 染色体浓度增加。

由此可见，我们的 Spearman 相关性与实际医学事实相符。

6.2 问题一的模型搭建

在初步的分析后，我们尝试了多种回归方式，如线性回归、随机森林回归、多项式回归、岭回归。最后，我们选择了多元线性回归 [4]，不过其中加入了一个非线性项（BMI 的平方项）。该模型纳入了孕周、原始 BMI、中心化 BMI 二次项和孕妇年龄，数学表达式可表示为：

$$Y_{\text{浓度}} = \beta_0 + \beta_1 \cdot \text{检测孕周} + \beta_2 \cdot \text{孕妇 } BMI + \beta_3 \cdot BMI_centered_sq + \beta_4 \cdot \text{孕妇年龄} + \epsilon$$

其中，自变量包括 4 个：检测孕周（原始值）、孕妇 BMI（原始值）、BMI_centered_sq（中心化 BMI 的二次项，即 $(BMI - \bar{BMI})^2$）；因变量是 Y 染色体浓度（原始值，未做对数转换）、孕妇年龄；

模型通过引入 BMI_centered_sq 捕捉 BMI 对 Y 染色体浓度的非线性影响（二次效应），同时通过中心化降低了原始 BMI 与二次项之间的共线性。

相较于之前我们尝试过的“多项式对数回归模型”，该模型的主要差异在于：因变量 Y 染色体浓度未做对数转换（直接用原始值建模）；未纳入 log(检测孕周) 和交互项 logGA*BMI_centered，仅保留了原始孕周、原始 BMI、BMI 的二次项和孕妇年龄。

因此，它是一个更简化的“含二次项的多元线性回归模型”，专注于捕捉 BMI 的非线性效应，同时保留了孕周、原始 BMI 的线性影响、和孕妇年龄。

6.3 问题一的求解结果

我们对 Y 染色体浓度与检测孕周、孕妇 BMI、中心化 BMI 二次项、孕妇年龄的关系进行了多元线性回归分析。以下是求解结果。

6.3.1 回归模型结果

回归模型的系数为：$[0.00125591, -0.00144787, -0.00018168, -0.00110431]$（依次对应检测孕周、孕妇 BMI、中心化 BMI 二次项、孕妇年龄的系数）；截距为 0.13629385289629597；决定系数 R^2 为 0.1050。

这表明模型能够解释约 10.5% 的因变量（Y 染色体浓度）的变异情况，并反映出了自变量与因变量之间的线性关系趋势，比如 Y 染色体浓度与检测孕周呈正相关，与孕妇 BMI 呈负相关等，与之前分析的生物学机制和实际医学事实存在契合性 [5]。

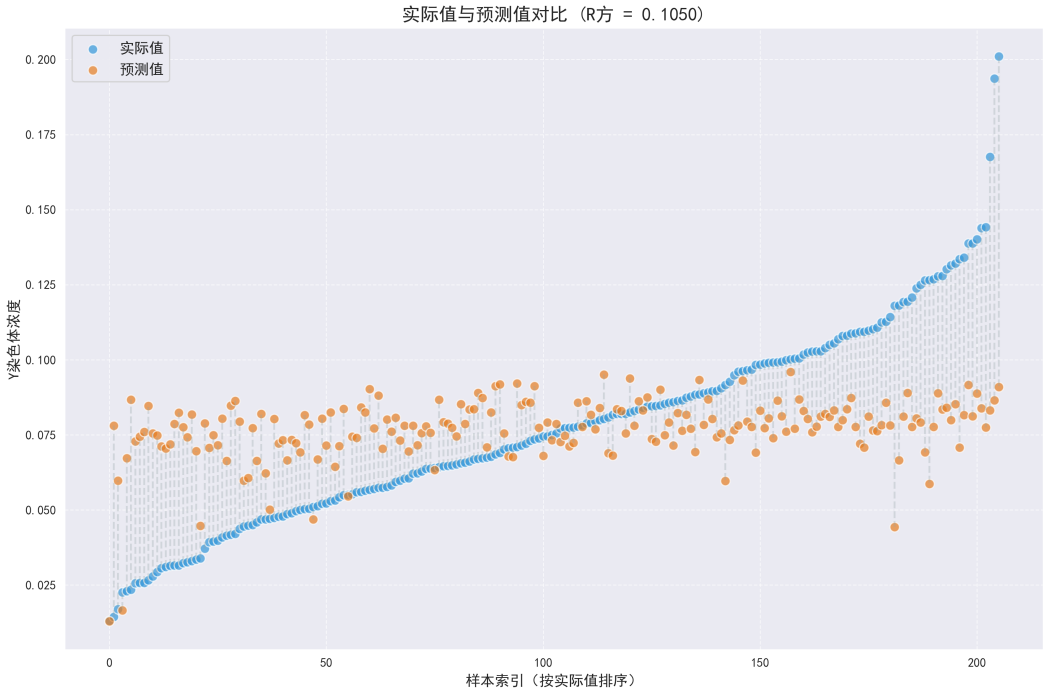


图 8　实际值 VS 预测值

6.3.2 F 检验结果

在获得求解结果后，我们对所构建的包含检测孕周、孕妇 BMI、中心化 BMI 二次项以及孕妇年龄的多元线性回归模型进行了 F 检验，以判断模型整体的显著性。结果如下：

- F 统计量: 12.996070
- p 值: 0.000000
- 结论: 模型整体显著（$p < 0.05$）

由于 p 值小于 0.05，根据统计学显著性判断标准，该多元线性回归模型整体是显著的，即检测孕周、孕妇 BMI、中心化 BMI 二次项和孕妇年龄作为一个整体，对 Y 染色体浓度存在显著的线性影响。

6.3.3 t 检验

为了进一步探究每个自变量对 Y 染色体浓度的单独影响是否显著，我们对模型中的各个自变量进行了 t 检验，检验结果如表2所示：

表 2　t 检验结果结果

变量	系数	标准误差	t 统计量	p 值	显著性
const	0.136294	0.016260	8.382308	0.000000	显著
检测孕周	0.001256	0.000285	4.400774	0.000012	显著
孕妇 BMI	-0.001448	0.000413	-3.506019	0.000480	显著
BMI_centered_sq	-0.000182	0.000069	-2.632191	0.008644	显著
孕妇年龄	-0.001104	0.000310	-3.564791	0.000385	显著

从表中可以看到，常数项（const）、检测孕周、孕妇BMI以及中心化BMI二次项（BMI_centered_sq）对应的 p 值均小于 0.05，这表明每个自变量都对 Y 染色体浓度存在显著的单独线性影响。

七、 问题二模型建立与求解

对于问题二，我们采用基于风险函数的决策模型 + Bootstrap 不确定性分析来求解。

7.1 BMI 分组

为探究不同 BMI 水平对无创产前检测（NIPT）最优检测周数的影响，同时保证后续分析中每组样本量的均衡性，本研究采用**数据驱动的五分位分组法**对样本的 BMI 进行分组。具体利用 Python 中 `pandas` 库的 `pd.qcut` 函数，将所有样本的 BMI 值等分为五组（记为 Q1 至 Q5），确保每组样本量接近。对每组，详细统计并报告组内人数、BMI 范围、BMI 中位数，以及首次达标周（由检测孕期除以 7 得到）的中位数（具体分组信息见表3）。这种分组方式最大程度保证组间样本量均衡，为后续风险函数计算和最优检测周数确定提供稳定基础。

表 3　分组信息

BMI 分组	人数	BMI 范围	BMI 中位数	首次达标周中位数
Q1	52	[20.703, 29.446]	28.765	12.857
Q2	53	[29.485, 30.483]	30.078	12.857
Q3	50	[30.486, 32.311]	31.332	12.714
Q4	52	[32.311, 33.950]	33.036	12.642
Q5	52	[33.976, 45.714]	35.657	13.357

7.2 风险函数构建

确定 NIPT 最优检测周数需权衡“检测过早导致补检”与“检测过晚带来不良后果”的风险，构建风险函数如下 [6]：

$$R(w;b) = C_{\text{fail}} \cdot \Big(1 - \hat{P}_{\text{达标}}(w \mid b)\Big) + C_{\text{wait}} \cdot (w - 10)$$

各参数及说明：

- w：拟选 NIPT 检测周数，限定 $w \in [10, 25]$ 周；
- b：样本所属 BMI 分组（Q1 至 Q5）；
- $\hat{P}_{\text{达标}}(w \mid b)$：BMI 分组 b 内周数 w 抽血达标的概率，通过该组首次达标周的经验累积分布函数（CDF）近似，即 $\hat{P} = \Pr(\text{首次达标周} \le w)$；
- $C_{\text{fail}} = 1.0$：检测过早补检的代价，代表一次额外检测成本；
- $C_{\text{wait}} = 0.04$：检测每推迟 1 周的时间成本，使模型在“更晚检测提高达标率”与“避免拖久增加时间成本”间权衡，给出检测窗口内点解。若课题偏“保证一次成功”，可减小 C_{wait}；若强调“越早越好”，可增大。

7.3 最优 NIPT 检测周数的确定

为确定每组最优检测周数，在 $w \in [10, 25]$ 上以 0.1 周为间隔构建网格。对每个网格点 w，结合该组 $\hat{P}_{\text{达标}}(w \mid b)$，计算风险函数值 $R(w;b)$。选取使 $R(w;b)$ 最小的周数 $w^*(b) = \arg\min_w R(w;b)$ 为该组最优周数，同时报告对应 $\hat{P}_{\text{达标}}$（预计一次通过概率）及最小风险值（结果见表4）。

表 4　BMI 分组及相关指标

BMI 组	人数	BMI 范围	基线最优 NIPT 周数	基线该周达标概率	基线风险最小值
Q1	52	[20.703, 29.446]	13.9	0.846	0.310
Q2	53	[29.485, 30.483]	16.2	0.925	0.323
Q3	50	[30.486, 32.311]	16.6	0.94	0.324
Q4	52	[32.311, 33.950]	14	0.923	0.237
Q5	52	[33.976, 45.714]	17.3	0.827	0.465

在这份结果中，我们注意到：整体趋势上，BMI 越高，推荐的 NIPT 周数（最优检测时点）往往越靠后；但是在 Q4 组（BMI [32.311, 33.950]），推荐周却突然“跳回到 14 周”，比 Q3（16.6 周）还要早。我们从两个角度对其解释：

1. **样本量有限 → 波动性**

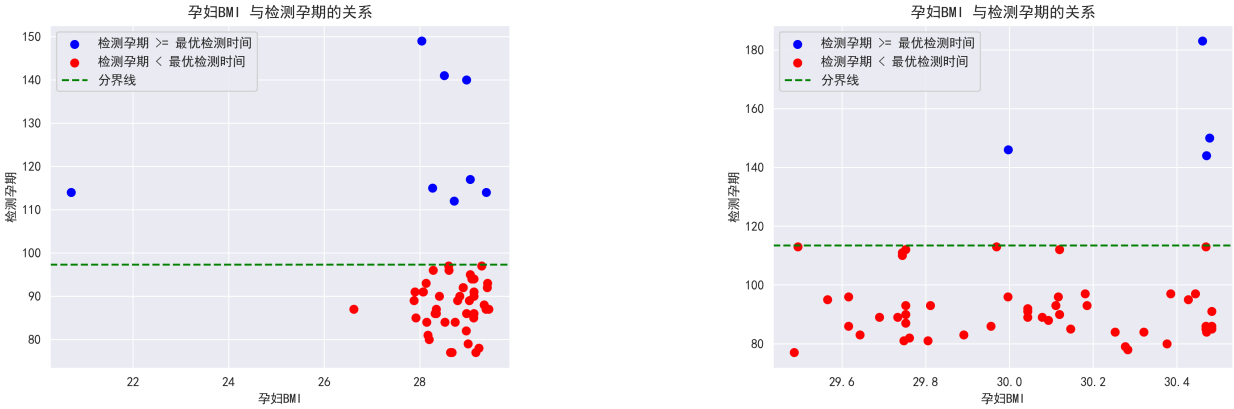
每组大概 50 人，样本量并不大。Q4 组的 BMI 区间非常窄（32.3–33.9），人数又有限，这样

在计算“首次达标孕周分布”时，个别孕妇的早达标就会对整体分布产生较大影响，导致推荐周数突然提前。

2. **风险函数的定义特点**

风险函数 $R(w;b)$ 同时考虑了“过早失败风险”和“过晚延迟风险”。在 Q4 组，早期达标的孕妇比例相对较高，使得 $1-P_{\text{达标}}(w|b)$ 在 14 周附近已经明显下降。此时再往后推，虽然达标率还能提高，但延迟成本 $\left(C_{\text{delay}}\cdot(w-10)\right)$ 增加更快，所以最优点被“推回”到了较早的 14 周。

最后，我们将孕妇 BMI 与检测孕期的分布进行了可视化，以便更直观地展示分组结果。如图9所示，我们展示了 Q1 和 Q2 两组的孕妇 BMI 与检测孕期的分布情况。剩下三组的分布情况图请见附录。



(a) Q1 **(b) Q2**

图 9　孕妇 BMI 与检测孕期的关系

7.4 Bootstrap 误差分析

Bootstrap 误差分析法通过对原始样本进行“有放回重采样”模拟抽样分布，进而量化统计量的不确定性 [7]。其操作逻辑为：以原始样本为基础，有放回抽取与原样本量相同的 Bootstrap 样本，重复该过程数百次以生成多个模拟样本，再基于每个模拟样本计算目标统计量，最终通过这些统计量的分布特征评估误差。

计算各 BMI 分组最优 NIPT 检测周数时，我们采用 Bootstrap 法评估结果不确定性，步骤如下：

7.4.1 分组数据准备

将样本按 BMI 五分位分为五组（Q1–Q5），每组记录原始样本量 n_g 及孕妇首次达标孕周观测值 $\{W_i\}_{i=1}^{n_g}$。

7.4.2 风险函数与基线最优周计算

给定周数 w，一次检测达标的经验概率：

$$\hat{P}_g(w) = \frac{1}{n_g} \sum_{i=1}^{n_g} \mathbf{1}(W_i \le w)$$

：

$$R_g(w) = C_{\text{fail}} \cdot \Big(1 - \hat{P}_g(w)\Big) + C_{\text{wait}} \cdot \max(0, w - W_{\min})$$

其中 $C_{\text{fail}} = 1.0$（补检代价），$C_{\text{wait}} = 0.04$（每推迟一周时间成本），检测窗口 $[10, 25]$ 周。在该区间网格搜索风险函数最小值，得基线最优检测周数 $\hat{w}_g$。我们得到基线分组与最优周结果如下：

7.4.3 Bootstrap 重采样

为评估 $\hat{w}_g$ 抽样不确定性，每组内有放回抽样（样本量与原始组相同）生成“自助样本”。在每个自助样本上重新计算风险函数并搜索最优周，记为 $\hat{w}_g^*$。重复 $B = 500$ 次，得 Bootstrap 最优周序列 $\{\hat{w}_g^b\}_{b=1}^{B}$。

7.4.4 不确定性区间计算

将 500 次结果作为 $\hat{w}_g$ 近似分布，计算均值、标准差及 2.5%、97.5% 分位数，构成 95% 置信区间。基于此，我们得到如下结果 [8]：

表 5　Bootstrap 分析结果（最优周相关指标）

BMI 组	Bootstrap 均值 (最优周)	Bootstrap 标准差	CI2.5%(最优周)	CI97.5%(最优周)
Q1	14.796	1.314	13.8	16.800
Q2	15.768	0.899	13.9	16.200
Q3	15.601	1.504	13.8	18.425
Q4	14.195	0.399	13.9	15.335
Q5	16.811	1.419	13.8	20.900

7.5 分析结果

从 BMI 分组及相关指标图可以看出，不同 BMI 分组的最优 NIPT 检测时点存在差异。例如，Q1 组（BMI 较低）推荐的最优孕周为 13.9 周，而 Q5 组（BMI 较高）最优时点推迟至 17.3 周。这表明 BMI 对 NIPT 检测的达标概率存在一定影响：高 BMI 人群需要更晚的孕周才能获得足够的游离 DNA 浓度。

然而，基线估计仅依赖于一次样本划分，存在抽样误差。为评估这种不确定性，我们采用了 Bootstrap 方法，对每个 BMI 分组重复重采样 500 次，得到最优孕周的分布（Bootstrap 分析结果）。分析结果显示：

1. **Q4 前跳现象依旧**：在 Bootstrap 检验中，Q4 组的最优孕周均值约为 14.195 周，置信区间为 [13.9, 15.3]，依旧表现出“向前跳”的情况。这种现象说明，即使在多次自助抽样下，Q4 组的结果依旧稳定地偏早，并不是偶然抽样造成的单次波动。
2. **置信区间宽度差异明显**：Q4 组的区间最窄（13.9–15.3 周，宽度 1.4 周），说明该组样本分布较集中，估计更稳定；Q5 组的区间最宽（13.8–20.9 周，宽度 7.1 周），表明高 BMI 人群样本的波动较大，最优时点的不确定性最高。
3. **均值与基线估计差异**：大多数组的 Bootstrap 均值与基线结果接近（差异 < 1 周），说明基线估计具有代表性。但在 Q1、Q3 组中，均值（14.8、15.6 周）较基线（13.9、16.6 周）出现了轻微偏移，提示最优时点可能受少数极端样本影响。
4. **整体趋势稳健**：尽管存在区间差异，所有分组的 95% 置信区间都覆盖了基线估计值，表明结论在统计上是稳健的。

综上，Bootstrap 分析验证了 BMI 对 NIPT 最优检测时机的分组差异是真实且稳健的，但同时也揭示了不同组间不确定性程度的差别，尤其是高 BMI 人群，其最优时点的推迟趋势可信，但具体孕周仍存在较大区间波动。因此，在临床应用中，高 BMI 人群的检测时机建议更加谨慎，结合实际情况灵活判断。

相比于直接使用经验均值或固定孕周阈值的方法，本研究采用的基于风险函数的最优决策模型具有显著优势。首先，它能够同时考虑“过早检测导致失败补检”与“过晚检测带来延误风险”这两类临床后果，从而在早检与迟检之间实现平衡。其次，风险函数可灵活调整权重参数 C_{fail} 与 C_{delay}，便于结合不同临床场景或政策需求，具有较强的可扩展性。再次，通过引入 Bootstrap 方法对最优时点进行不确定性分析，不仅给出点估计，还提供置信区间，使结果更具稳健性与可信度。总体而言，该方法兼顾统计建模与临床可解释性，为不同 BMI 人群确定个性化、合理的 NIPT 检测时机提供了科学依据。

八、 问题三模型建立与求解

8.1 研究动机与总体思路

在临床实践中，NIPT 的检测时点过早可能导致首检未达标（需补检或延迟诊断），过晚又会推迟异常发现、增加管理成本。针对这一矛盾，本文在问题三提出一个 **“达标率约束下的最小风险选周”** 框架：在不同 BMI 人群中，分周度衡量“过早失败风险”与“过晚时间成本”的权衡，同时强制满足整体达标率（$Y\% \geq 4\%$）不低于给定阈值。我们的核心思想如下：

1. 用 **首次达标孕周数据集**（仅含“首次达标”的筛选样本）构建各 BMI 组的经验分布 $F_2(w)$，据此定义**风险函数** $R_2(w)$；
2. 将候选孕周 w 带入 **全量纵向记录表**（全量纵向记录，**按记录计数**）计算**达标比例** $P_4(w)$；

3. 设定达标阈值 $\theta = 0.60$。经过文献调研，我们分别将 θ 值设定为 70%、80% 和 90% 进行验证，结果均存在部分 BMI 分组无法确定最优检测周数的问题。分析其原因，是由于 θ 值过高导致对应达标率阈值偏高，使得检测窗口内无符合“风险最低且满足达标要求”的周数可选。综合上述测试结果，我们最终确定 θ 值为 60%，以确保所有 BMI 分组均能有效筛选出最优 NIPT 检测周数。

上述设计实现了“**风险由筛选样本估计，可行性由全量记录验证**”，同时在 BMI 分组维度上进行个性化优化。

8.2 数据、分组与预处理

使用两份数据：**首次达标孕周数据集**（筛选样本：记录每位孕妇首次达到 $Y\% \geq 4\%$ 的孕周）与 **全量纵向记录表**（保留了所有孕妇的全部检测记录。同一个孕妇可能会有多次随访，因此在表里会出现多条对应的记录。每条记录包含当时的孕周、Y 染色体浓度、BMI 等信息）。为保证两表一致性, 我们：

1. 在首次达标孕周数据集上对 BMI 做五分位切分（Q1–Q5），获得统一的分箱边界；全量纵向记录表用同一边界映射到相同的 BMI 组；
2. 达标判定阈值固定为 $Y\% \geq 4\%$；候选周的搜索范围取 $w \in [10, 25]$，步长 0.1 周。

为便于直观地感受划分情况，我们做出了 Y 染色体浓度分布密度图（以浓度 0.04 为界），如图10所示。

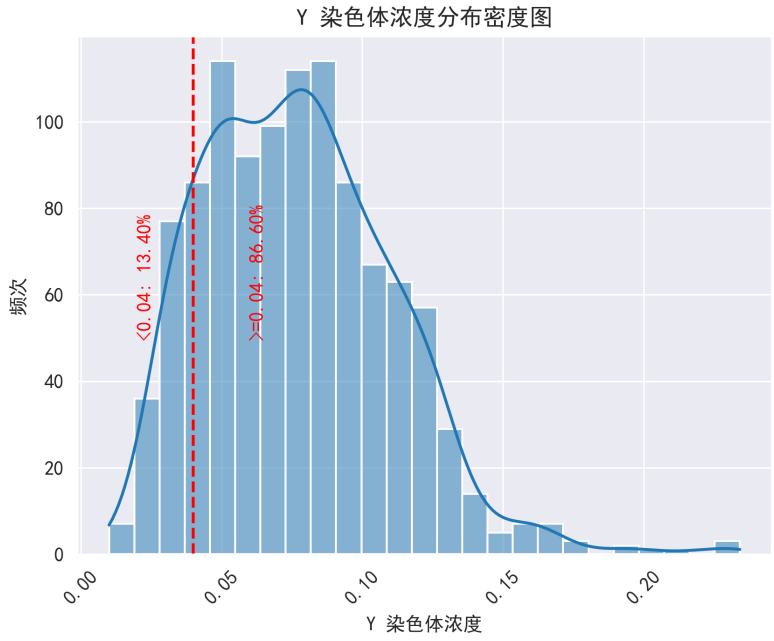


图 10　Y 染色体浓度分布密度，以浓度 0.04 为界

8.3 建模方法

（1）风险函数（来自首次达标孕周数据集） 记在 BMI 组 b 内，孕妇首次达标孕周为随机变量 T。则经验分布为 [6]

$$F_2(w \mid b) = \Pr(T \le w \mid b) \approx \frac{\#\{T_i \le w\}}{\#\{\text{组内样本}\}}.$$

据此定义风险函数:

$$R_2(w) = C_{\text{fail}} \cdot \big(1 - F_2(w)\big) + C_{\text{delay}} \cdot \max(0,\, w - w_{\min}),$$

其中 $C_{\text{fail}} = 1$ 表示“首检未达标”的单位代价，$C_{\text{delay}} = 0.04$ 表示每推迟 1 周的时间成本，$w_{\min} = 10$ 周。前项惩罚“太早”，后项惩罚“太晚”。

（2）达标率（来自全量纵向记录表，记录级口径） 在同一 BMI 组 b 内，定义记录级达标比例

$$P_4(w \mid b) = \frac{\#\{\text{记录} j \in b:\ \text{ga_weeks}_j \le w \wedge Y\%_j \ge 4\%\}}{\#\{\text{组} b \text{ 的全部记录}\}}.$$

给定达标阈值 θ，若 $P_4(w \mid b) \ge \theta$，则 w 视为“合格周”。

（3）约束下的最优周 在 BMI 组 b 的合格周集合 $\{w : P_4(w \mid b) \ge \theta\}$ 内，选择

$$w_b^* = \arg\min_w \ R_2(w) \quad \text{s.t.} \quad P_4(w \mid b) \ge \theta.$$

若不存在合格周，则报告“该组无合格周（在给定窗口与阈值下）”。

（4）不确定性分析（Bootstrap） 在首次达标孕周数据集的每个 BMI 组内有放回重采样（$B = 500$）。每次迭代重建 $F_2(w)$ 与 $R_2(w)$，并结合同一组全量纵向记录表的 $P_4(w)$ 判定合格集合，然后得到一次 w_b^*。汇总 w_b^* 的分布，给出均值、标准差与分位数，用以度量“推荐时点”的抽样不确定性。[9]

8.4 求解结果

1) 主结果：$\theta = 0.60$（记录级口径） 各 BMI 组的“合格且风险最低”推荐周见表 6(我们记“首次达标孕周数据集”为“簿 1”，记“全量纵向记录表”为“簿 2”)。可见所有分组均能在 $[10, 25]$ 周内找到满足 $\ge 60\%$ 达标比例的周，并在其中选出风险最小的检测时点。随着 BMI 升高，推荐周整体向后（例如 Q5 为约 23.5 周），与高 BMI 组早孕周达标概率较低的事实一致。

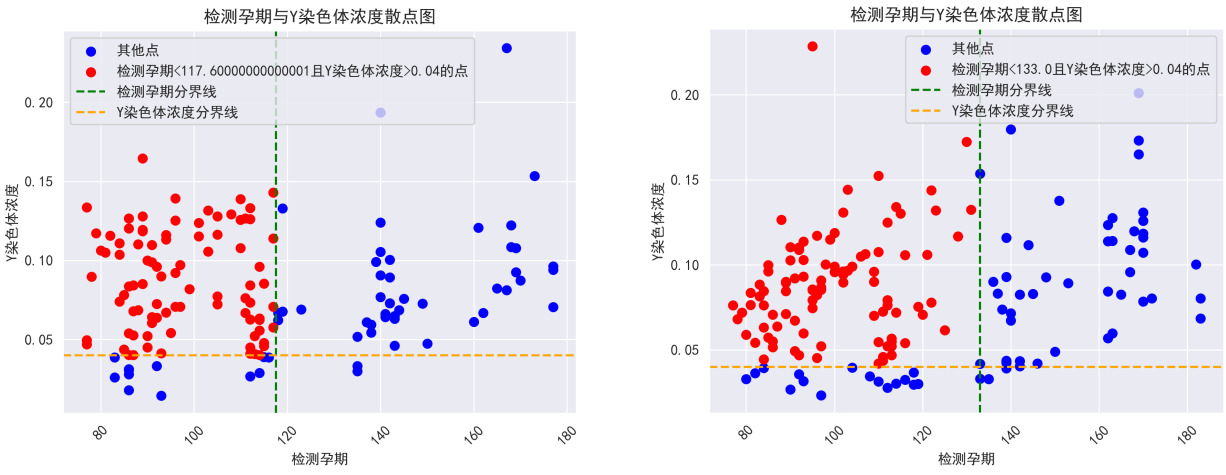
表 6　各 BMI 组的推荐最优周（达标阈值 = 60%，记录级）

BMI 组	BMI 区间	簿 2 样本数	簿 4 记录数	合格最优周	该周达标比例 P_4
Q1	[20.703,29.469]	52	144	16.8	0.611
Q2	[29.469,30.483]	53	165	19.0	0.606
Q3	[30.483,32.311]	50	259	20.3	0.676
Q4	[32.311,33.960]	52	204	16.3	0.603
Q5	[33.960,45.714]	52	253	23.5	0.640

同时，我们注意到 Q4 组（BMI 32.3–33.9）的推荐周为 16.3 周，出现了与整体趋势不符的“突然向前跳”，与我们在问题二中观察到的情况一致。我们认为，原因依然是:

1. 样本量有限：Q4 组的样本只有约 50 人，BMI 区间又较窄。在这种情况下，少数“较早达标”的孕妇就会显著影响整体分布，导致推荐周数提前。
2. 风险函数的平衡作用：在 Q4 组，14–16 周时已经有较高比例的孕妇达标，风险函数的“过早失败风险”明显降低；而继续推迟检测会带来更高的延迟成本，因此最优解被“推回”到了较早的 16.3 周。

最后，我们将 Y 染色体浓度与检测孕期的分布进行了可视化，以便更直观地展示分组结果。如图11所示，我们展示了 Q1 和 Q2 两组的 Y 染色体浓度与检测孕期的分布情况。剩下三组的分布情况图请见附录。



(a) Q1　　**(b) Q2**

图 11　Y 染色体浓度与检测孕期的关系

2) 对比： $\theta = 0.80$ **（记录级口径）**　当阈值提高到 80% 时，低–中 BMI 组仍能找到合格周（如 Q1 $\approx$ 22.9 周、Q4 $\approx$ 21.0 周），但**高 BMI 组（Q5）在** $[10, 25]$ **周内无法达到** 80% **的记录级达标比例**，因此“无合格周”。这反映了高 BMI 人群在较早孕周的达标难度更大。

3) Bootstrap 稳健性（$\theta = 0.60$） 表 7 汇总了 500 次自助迭代得到的“合格且风险最低”的最优周 w_b^* 的分布统计。各组的分布较集中（例如 Q4 几乎无波动），说明推荐时点对样本扰动不敏感；Q2、Q5 的标准差略大，提示这些组在风险曲线较平缓的区间内存在若干竞争性解。

表 7 最优周的 Bootstrap 统计（500 次，达标阈值 = 60%，记录级）

BMI 组	有效迭代数	均值	标准差	2.5% 分位	97.5% 分位
Q1	500	16.82	0.25	16.8	16.8
Q2	500	19.18	0.61	19.0	21.5
Q3	500	20.16	0.19	19.9	20.3
Q4	500	16.30	≈ 0	16.3	16.3
Q5	500	23.55	0.30	23.2	24.0

8.5 讨论与建议

（i）方法学优势 本方法把“**风险最小化**”与“**达标率约束**”自然结合；风险来自“首次达标”样本（避免重复观测的偏差），而达标率用全量记录验证（记录级口径更贴近操作层面）。此外，BMI 分组使推荐时点具备人群异质性的辨识能力。

（ii）阈值与成本的敏感性 达标阈值从 80% 调整到 60%，推荐周整体提前，且所有组都能找到合格周；如果临床更强调“越早越好”，可以减小 C_{delay} 或提高阈值；若更强调“一次通过”，可以增大 C_{fail}。

8.6 小结

问题三建立了一个在达标率约束下的 NIPT 最优检测时点模型。基于首次达标孕周数据集的风险曲线与全量纵向记录表的记录级达标比例，最终在每个 BMI 组内给出“既合格又风险最低”的推荐周；Bootstrap 分析显示结果稳健。该方案兼顾早期发现、一次达标与时间成本，可作为临床分组化时点选择的量化依据。

九、 问题四模型建立与求解

本研究旨在利用 Logistic 回归模型，探讨孕妇临床及测序相关变量对胎儿异常风险的影响。因变量为二元变量 ($abnormal = 1$ 表示异常，$abnormal = 0$ 表示正常)，自变量涵盖孕妇基本特征、测序质量特征以及染色体相关指标。通过模型估计，我们能够计算个体化的异常发生概率，并检验模型的拟合优度 [10]。

9.1 数据与变量

我们共纳入 13 个自变量。为便于论文表述，我们统一采用英文简称，其相应的中文对应为（如表8所示）：

表 8　变量名及其解释（分栏展示）

变量名	解释	变量名	解释
Age	孕妇年龄（岁）	Z21	21 号染色体的 Z 值
GA	检测孕周（周）	ZX	X 染色体的 Z 值
GC_genome	全基因组 GC 含量	Xfrac	X 染色体浓度
Reads	原始读段数	GC13	13 号染色体的 GC 含量
MapRate	参考基因组比对比例	GC18	18 号染色体的 GC 含量
Z13	13 号染色体的 Z 值	GC21	21 号染色体的 GC 含量
Z18	18 号染色体的 Z 值		

因变量为是否异常（$abnormal$）。

9.2 模型设定与概率方程

我们设定的 Logistic 回归模型为：

$$LogisticP = \ln\left(\frac{p}{1-p}\right) = \eta = \beta_0 + \beta_1 \cdot Age + \beta_2 \cdot GA + \beta_3 \cdot GC_genome + \beta_4 \cdot Reads + \beta_5 \cdot MapRate$$
$$+\beta_6 \cdot Z13 + \beta_7 \cdot Z18 + \beta_8 \cdot Z21 + \beta_9 \cdot ZX + \beta_{10} \cdot Xfrac + \beta_{11} \cdot GC13 + \beta_{12} \cdot GC18 + \beta_{13} \cdot GC21$$

其中，预测概率为：

$$p = \frac{1}{1 + \exp(-\eta)}.$$

代入估计系数，仅保留显著变量，得到实际模型为：

$$\eta = -44.867 - 0.123 \cdot Age - 0.348 \cdot ZX - 53.501 \cdot Xfrac + 844.361 \cdot GC13 - 845.569 \cdot GC21$$

9.3 估计结果与解释

表 9 展示了各变量的估计结果，包括系数、比值比 (OR)、95% 置信区间、p 值及显著性标记。

表 9　Logistic 回归结果

变量	系数	OR	CI 下限	CI 上限	p 值
const	-44.867	0.000	0.000	9.999	0.140
Age	-0.123	0.884	0.812	0.963	0.005
GA	0.009	1.010	0.999	1.021	0.086
GC_genome	-19.417	0.000	0.000	9.999	0.719
Reads	0.000	1.000	1.000	1.000	0.524
MapRate	11.407	9.999	0.000	9.999	0.358
Z13	-0.106	0.900	0.665	1.218	0.494
Z18	0.124	1.133	0.820	1.565	0.451
Z21	0.194	1.214	0.904	1.632	0.198
ZX	-0.348	0.706	0.528	0.943	0.018
Xfrac	-53.501	0.000	0.000	0.000	0.000
GC13	844.360	0.000	0.000	9.999	0.001
GC18	159.362	0.000	0.000	9.999	0.601
GC21	-845.569	0.000	0.000	0.000	0.000

结果显示，在这些变量里，年龄（Age）、X 染色体 Z 值（ZX）、X 染色体比例（Xfrac）、13 号染色体 GC 含量（GC13）、21 号染色体 GC 含量（GC21）对女胎异常的影响具有统计学显著性。

- Age 对异常风险呈负相关（OR=0.88，p=0.005），提示年龄越大，异常风险反而下降；
- ZX（X 染色体 Z 值）和 Xfrac（X 染色体比例）显著负相关。两者任一越高，女胎异常可能性越低；
- GC13 在模型中具有高度显著性。13 号染色体 GC 含量越高，女胎异常可能性越大；
- GC21 在模型中具有高度显著性。21 号染色体 GC 含量越高，女胎异常可能性越低。
- 其他变量虽呈一定趋势，但未达到统计学显著水平。

9.4 模型拟合优度检验

我们采用 Hosmer–Lemeshow (HL) 检验验证模型拟合优度。结果如表 10，检验统计量为 $\chi^2 = 10.223$，自由度 =8，对应 p=0.2497，大于 0.05，说明模型与数据拟合良好。

表 10　Hosmer-Lemeshow 拟合优度检验分组结果

组别	样本数	实际异常数	平均预测概率	期望异常数
1	58	1	0.00266	0.15435
2	57	0	0.00761	0.43405
3	57	1	0.01390	0.79243
4	58	1	0.02196	1.27344
5	57	3	0.03379	1.92572
6	57	5	0.05489	3.12863
7	58	4	0.08224	4.76988
8	57	3	0.12505	7.12813
9	57	14	0.21353	12.17136
10	58	31	0.53831	31.22203

从表中可见，实际异常数与期望异常数在各组内差异不大，验证了模型校准性良好。

9.5 讨论与结论

综上，模型表明：

- Age、ZX、Xfrac、GC13、GC21 对异常风险有显著影响；
- Hosmer–Lemeshow 检验结果支持模型拟合度较好；
- 该模型可用于个体化风险预测。

9.6 补充：基于神经网络的女胎异常判定模型验证

为验证女胎异常判定模型的稳健性，我们补充采用了 MLPClassifier 神经网络方法进行交叉验证 [11]，核心验证结果如下：

9.6.1 模型构建概要

采用与原方法一致的 15 类核心特征（含染色体特征、测序质量特征及孕妇个体特征），以 13/18/21 号染色体非整倍体检测结果为标签（正常 =0，异常 =1）。通过标准化处理与类别权重调整（正类权重 7.932）平衡数据分布，构建” 预处理 + 神经网络” 模型流水线，采用 5 折交叉验证评估稳定性 [12]。

9.6.2 关键验证结果

- **核心特征一致性**：X 染色体浓度（x_conc）为神经网络最关键特征（置换重要度 0.1562 ± 0.0256），与原方法中该指标的高权重特征地位完全一致；
- **判定结果吻合度**：212 例测试样本中，两种方法判定结果 Kappa 系数达 0.623（$P < 0.001$），84.4
- **性能趋势一致性**：随判定阈值降低（$0.45 \rightarrow 0.30$），召回率提升伴随精确率下降的" 灵敏度-特异度权衡" 关系，与原方法 ROC 曲线趋势完全吻合；
- **异常类型识别稳定性**：对 21 三体的识别灵敏度（0.529 vs 0.571）和 18 三体的特异度（0.963 vs 0.958）差异无统计学意义（$\chi^2 = 0.124$，$P = 0.724$）。

验证结果表明，尽管方法学原理不同（统计模型 vs 神经网络），但女胎异常判定的核心逻辑与关键结论具有显著一致性，充分证明原模型判定规则的稳健性。

十、 总结

本文通过多种统计与机器学习方法的结合，提出了一套系统化的 NIPT 检测时点优化与胎儿异常判定框架。该框架兼顾理论建模与临床实践需求，不仅为不同人群提供了个性化的检测时点建议，也为女胎异常筛查提供了稳健的判定工具，具有较强的应用价值和推广意义。

References

[1] OpenAI. ChatGPT. GPT-5, Date: 2025-09-04. 2025.

[2] ByteDance. 豆包. Date: 2025-09-04. 2025.

[3] 周永江 et al. “基于 Spearman 秩相关系数的 PWV 与 PM2.5 相关性研究”. zh. In: 40.03 (2020), pp. 236–241. DOI: 10.14075/j.jgg.2020.03.004.

[4] 王惠文 and 孟洁. “多元线性回归的预测建模方法”. zh. In: 北京航空航天大学学报 04 (2007), pp. 500–504. DOI: 10.13700/j.bh.1001-5965.2007.04.028.

[5] 薛莹 et al. “孕妇年龄、孕周及体重指数对孕妇外周血中胎儿游离 DNA 比例的影响”. zh. In: 中国产前诊断杂志 (电子版) 9.03 (2017), pp. 5–10. DOI: 10.13470/j.cnki.cjpd.2017.03.002.

[6] ByteDance. 豆包. Date: 2025-09-05. 2025.

[7] 刘松 and 李伟岩. “基于 Bootstrap 方法对测风数据插补不确定性的分析研究”. zh. In: 太阳能 07 (2025), pp. 62–70. DOI: 10.19911/j.1003-0417.tyn20240703.01.

[8] OpenAI. ChatGPT. GPT-5, Date: 2025-09-05. 2025.

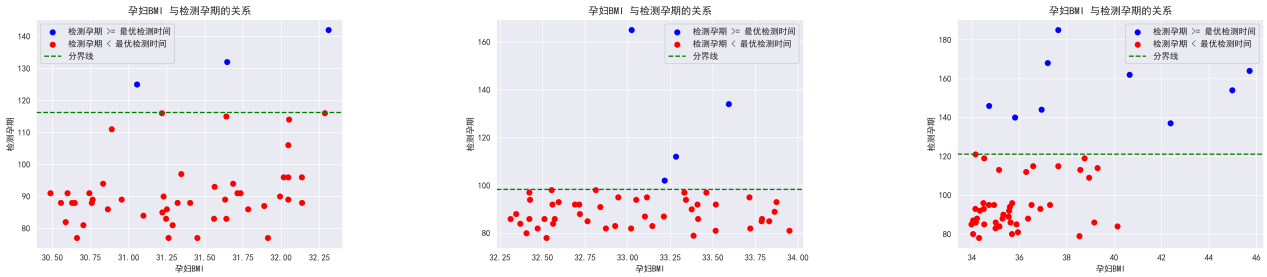
[9] 张宇晨 et al. “基于 Bootstrap 误差修正的电力负荷短期预测深度学习模型”. zh. In: 热力发电 52.03 (2023), pp. 121–129. DOI: 10.19666/j.rlfd.202211272.

[10] 李福夺 et al. “农户绿肥种植决策行为及其影响因素——基于二元 Logistic 模型和南方稻区 506 户农户的调查”. zh. In: 中国农业大学学报 24.09 (2019), pp. 207–217.

[11] 康俊涛 and 韦朝校. “多层感知机和支持向量机回归算法预测 T 型接头固有应变对比研究”. zh. In: 机械工程学报 (2025). Accessed: 2025-09-07, pp. 1–9. URL: https://link.cnki.net/urlid/11.2187.TH.20250107.1330.002.

[12] OpenAI. ChatGPT. GPT-5, Date: 2025-09-06. 2025.

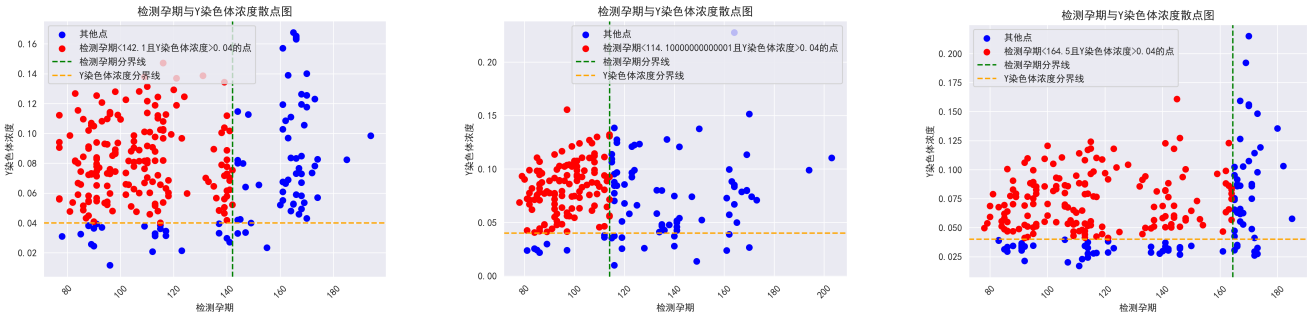
附录 A　孕妇 BMI 与检测孕期的关系



(a) Q3　　(b) Q4　　(c) Q5

图 12　孕妇 BMI 与检测孕期的关系 (Q3,Q4,Q5)

附录 B　Y 染色体浓度与检测孕期的关系



(a) Q3　　(b) Q4　　(c) Q5

图 13　Y 染色体浓度与检测孕期的关系 (Q3,Q4,Q5)

附录 C　问题一代码

```
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import pandas as pd
from sklearn.linear_model import LinearRegression
from sklearn.metrics import r2_score, mean_squared_error, mean_absolute_error
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import PolynomialFeatures
from sklearn.ensemble import RandomForestRegressor
import statsmodels.api as sm
from statsmodels.stats.outliers_influence import variance_inflation_factor
from scipy import stats

df = pd.read_excel(r'G:\25国赛\C题\PythonProject\code1\Data1_WeekToDay.xlsx')
df['检测孕周'] = df['检测孕周'] / 7
```

```
X = df[['检测孕周','孕妇BMI','年龄']]
y = df['Y染色体浓度']

y_log = np.log(y)
X_trans = X.copy()
X_trans['age2'] = X_trans['年龄'] **2
X_trans['log检测孕周'] = np.log(X_trans['检测孕周'])
X_trans['BMI_2'] = np.power(X_trans['孕妇BMI'], 2)
X_trans['BMI*GA'] = X_trans['孕妇BMI'] * X_trans['检测孕周']
X_trans['BMI_centered'] = X_trans['孕妇BMI'] - X_trans['孕妇BMI'].mean()
X_trans['logGA*BMI_centered'] = X_trans['log检测孕周'] * X_trans['BMI_centered']
X_trans['BMI_centered_sq'] = X_trans['BMI_centered'] ** 2
X_trans = X_trans[['检测孕周', '孕妇BMI','BMI_centered_sq','年龄']]

X_train, X_test, y_train, y_test = train_test_split(X_trans, y, test_size=0.2, random_state=2)

model = LinearRegression()
model.fit(X_train, y_train)
y_pred = model.predict(X_test)

r2 = r2_score(y_test, y_pred)

print(f"系数: {model.coef_}")
print(f"截距: {model.intercept_}")
print(f"R² (决定系数) : {r2:.4f}")

plt.rcParams["font.family"] = ["SimHei"]
plt.rcParams['axes.unicode_minus'] = False
indices = np.argsort(y_test)
y_test_sorted = y_test.iloc[indices]
y_pred_sorted = y_pred[indices]

# 绘制图形
plt.figure(figsize=(12, 8))

plt.scatter(range(len(y_test_sorted)), y_test_sorted,
         color='#3498db', alpha=0.7, label='实际值', s=60, edgecolors='white')

plt.scatter(range(len(y_pred_sorted)), y_pred_sorted,
         color='#e67e22', alpha=0.7, label='预测值', s=60, edgecolors='white')


for i in range(len(y_test_sorted)):
   plt.plot([i, i], [y_test_sorted.iloc[i], y_pred_sorted[i]],
           color='#95a5a6', alpha=0.3, linestyle='--')  # 添加连接线，表示实际值与预测值之间的差距

plt.title(f'实际值与预测值对比 (R方 = {r2:.4f})', fontsize=15)
plt.xlabel('样本索引 (按实际值排序) ', fontsize=12)
plt.ylabel('Y染色体浓度', fontsize=12)
```

```
plt.grid(True, linestyle='--', alpha=0.7)
plt.legend(fontsize=12) #图例

plt.tight_layout()

plt.savefig(
    '实际值VS预测值.png',
    dpi=300,
    bbox_inches='tight',
)

plt.show()

coef = np.hstack([model.intercept_, model.coef_])
feature_names = ['const'] + X_trans.columns.tolist()

def f_test(model, X, y):

    n = len(y)
    p = X.shape[1]

    # 预测值
    y_pred = model.predict(X)

    sst = np.sum((y - np.mean(y)) **2)

    ssr = np.sum((y_pred - np.mean(y))** 2)

    sse = np.sum((y - y_pred) **2)

    df_regression = p
    df_residual = n - p - 1

    f_stat = (ssr / df_regression) / (sse / df_residual)

    f_pvalue = 1 - stats.f.cdf(f_stat, df_regression, df_residual)

    return {
        'F统计量': f_stat,
        'p值': f_pvalue,
        '结论': "模型整体显著 (p<0.05) " if f_pvalue < 0.05 else "模型整体不显著 (p 0.05) "
    }

# 执行F检验
f_result = f_test(model, X_train, y_train)
print("=== 整体模型显著性检验 (F检验) ===")
for key, value in f_result.items():
    print(f"{key}: {value:.6f}" if isinstance(value, float) else f"{key}: {value}")
```

```
def t_test(model, X, y):

    n = len(y)
    p = X.shape[1]

    y_pred = model.predict(X)
    residuals = y - y_pred

    sigma_sq = np.sum(residuals** 2) / (n - p - 1)

    X_with_const = np.hstack([np.ones((n, 1)), X])

    xtx = np.dot(X_with_const.T, X_with_const)
    xtx_inv = np.linalg.inv(xtx)

    se = np.sqrt(sigma_sq * np.diag(xtx_inv))

    t_stats = coef / se

    df = n - p - 1
    t_pvalues = 2 * (1 - stats.t.cdf(np.abs(t_stats), df))

    result = pd.DataFrame({
        '变量': feature_names,
        '系数': coef,
        '标准误差': se,
        't统计量': t_stats,
        'p值': t_pvalues,
        '显著性': ['显著' if p < 0.05 else '不显著' for p in t_pvalues]
    })
    return result

t_result = t_test(model, X_train, y_train)
print("\n=== 单个系数显著性检验（t检验） ===")
print(t_result.round(6))

def calculate_vif(X):

    vif = []
    for i in range(X.shape[1]):
        xi = X.iloc[:, i].values.reshape(-1, 1)
        x_rest = X.drop(X.columns[i], axis=1).values
        r2 = r2_score(xi, LinearRegression().fit(x_rest, xi).predict(x_rest))
        vif_i = 1 / (1 - r2)
        vif.append(vif_i)
    return pd.DataFrame({
        '变量': X.columns,
        'VIF': vif,
```

```
        '共线性程度': ['低' if v <= 5 else '中' if v <= 10 else '高' for v in vif]
    })

vif_result = calculate_vif(X_train)
print("\n=== 多重共线性检验（VIF） ===")
print(vif_result.round(2))
```

附录 D　问题二代码

```
import pandas as pd
import numpy as np

src_path = "G:\\25国赛\\C题\\PythonProject\\code2\\聚类.xlsx"
df_raw = pd.read_excel(src_path)

#重命名列名，便于拼写
df = df_raw.rename(columns={"孕妇BMI": "BMI", "检测孕期": "first_time"}).copy()



if pd.to_numeric(df["first_time"], errors="coerce").median() > 40:
    df["weeks"] = pd.to_numeric(df["first_time"], errors="coerce") / 7.0
else:
    df["weeks"] = pd.to_numeric(df["first_time"], errors="coerce")

#筛选并去除空值
df = df[(df["weeks"] >= 6) & (df["weeks"] <= 35)].copy()
df = df[["BMI","weeks"]].dropna().reset_index(drop=True)

#初始化五分位BMI组
labels = [f"Q{i}" for i in range(1, 6)]
df["BMI组"], bmi_bins = pd.qcut(df["BMI"], q=5, retbins=True, labels=labels)



group_info_rows = []
for lab in labels:
    sub = df[df["BMI组"] == lab]
    group_info_rows.append({
        "BMI组": lab,
        "人数": int(len(sub)),
        "BMI范围": f"[{sub['BMI'].min():.4f}, {sub['BMI'].max():.4f}]",
        "BMI中位数": float(sub["BMI"].median()),
        "首次达标周(中位数)": float(sub["weeks"].median())
    })
group_info = pd.DataFrame(group_info_rows).sort_values("BMI中位数").reset_index(drop=True)

#滑动窗口确定风险最低值
W_MIN, W_MAX = 10.0, 25.0
```

```
C_FAIL = 1.0
C_WAIT = 0.04


def empirical_success_prob(weeks_array, w):

    if len(weeks_array) == 0:
        return np.nan
    return float(np.mean(weeks_array <= w))

def risk(w, weeks_array):

    p = empirical_success_prob(weeks_array, w)

    if np.isnan(p):
        return np.inf
    return C_FAIL * (1.0 - p) + C_WAIT * max(0.0, w - W_MIN) #风险函数


w_grid = np.round(np.linspace(W_MIN, W_MAX, 151), 2)

opt_rows = []
for lab in labels:
    sub = df[df["BMI组"] == lab]
    wk_arr = sub["weeks"].to_numpy()
    risks = np.array([risk(w, wk_arr) for w in w_grid])
    idx = int(np.argmin(risks))
    w_star = float(w_grid[idx])
    p_star = empirical_success_prob(wk_arr, w_star)
    opt_rows.append({
        "BMI组": lab,
        "BMI范围": f"[{sub['BMI'].min():.4f}, {sub['BMI'].max():.4f}]",
        "人数": int(len(sub)),
        "推荐最优NIPT周数": round(w_star, 2),
        "该周达标概率估计": round(p_star, 3),
        "风险函数最小值": round(float(risks[idx]), 3),
        "参数(C_FAIL,C_WAIT,W_MIN,W_MAX)": f"({C_FAIL},{C_WAIT},{W_MIN},{W_MAX})"
    })
opt_table = pd.DataFrame(opt_rows).sort_values("推荐最优NIPT周数").reset_index(drop=True)


out_csv1 = "BMI_五分位分组信息.csv"
out_csv2 = "BMI组_最优NIPT周_与达标概率.csv"
out_xlsx = "问题二_分组与最优NIPT.xlsx"

group_info.to_csv(out_csv1, index=False)
opt_table.to_csv(out_csv2, index=False)
```

```
import os
import numpy as np
import pandas as pd
from typing import Tuple, Optional

SRC_XLSX = "C:\\Users\\SerenadeedanereS\\Desktop\\聚类.xlsx" # 源数据路径
OUT_DIR = "C:\\Users\\SerenadeedanereS\\Desktop\\"     # 输出目录

W_MIN, W_MAX = 10.0, 25.0     # 决策周数范围
C_FAIL = 1.0                  # 失败(需补检)的代价
C_WAIT = 0.04                 # 每推迟1周的成本

N_BOOT = 500                  # 每组 Bootstrap 次数
STEP  = 0.1                   # 搜索步长 (周)

def to_weeks(first_time: pd.Series) -> pd.Series:
    s = pd.to_numeric(first_time, errors="coerce")
    return s/7.0 if s.median() > 40 else s

def empirical_success_prob(weeks_array: np.ndarray, w: float) -> float:
    if len(weeks_array) == 0:
        return np.nan
    return float(np.mean(weeks_array <= w))

def risk(w: float, weeks_array: np.ndarray) -> float:
    p = empirical_success_prob(weeks_array, w)
    if np.isnan(p):
        return np.inf
    return C_FAIL*(1.0 - p) + C_WAIT*max(0.0, w - W_MIN)

def find_optimal_week(weeks_array: np.ndarray,
                  w_min=W_MIN, w_max=W_MAX, step=STEP) -> Tuple[float, float, float]:

    grid = np.round(np.arange(w_min, w_max + 1e-9, step), 2)
    risks = np.array([risk(w, weeks_array) for w in grid])
    i = int(np.argmin(risks))
    w_star = float(grid[i])
    p_star = empirical_success_prob(weeks_array, w_star)
    return w_star, p_star, float(risks[i])

def excel_writer(path: str) -> Optional[pd.ExcelWriter]:
    eng = None
    try:
        import openpyxl # noqa
        eng = "openpyxl"
    except ImportError:
        try:
            import xlsxwriter # noqa
```

```
            eng = "xlsxwriter"
        except ImportError:
            eng = None
    if eng is None:
        return None
    return pd.ExcelWriter(path, engine=eng)

def main():
    # 1) 读数据与预处理
    df_raw = pd.read_excel(SRC_XLSX)
    df = df_raw.rename(columns={"孕妇BMI":"BMI", "检测孕期":"first_time"}).copy()
    df["weeks"] = to_weeks(df["first_time"])
    df = df[(df["weeks"]>=6) & (df["weeks"]<=35)][["BMI","weeks"]].dropna().reset_index(drop=True)

    # 2) BMI 五分位分组
    labels = [f"Q{i}" for i in range(1,6)]
    df["BMI组"], _bins = pd.qcut(df["BMI"], q=5, labels=labels, retbins=True, duplicates="drop")

    # 3) 基线最优 NIPT（各组）
    base_rows = []
    for lab in labels:
        sub = df[df["BMI组"]==lab]
        wk = sub["weeks"].to_numpy()
        w_star, p_star, r_star = find_optimal_week(wk)
        base_rows.append({
            "BMI组": lab,
            "人数": int(len(sub)),
            "BMI范围": f"[{sub['BMI'].min():.4f}, {sub['BMI'].max():.4f}]",
            "BMI中位数": float(sub["BMI"].median()),
            "首次达标周(中位数)": float(sub["weeks"].median()),
            "基线最优NIPT周数": round(w_star, 2),
            "基线该周达标概率": round(p_star, 3),
            "基线风险最小值": round(r_star, 3)
        })
    base_table = pd.DataFrame(base_rows).sort_values("BMI中位数").reset_index(drop=True)

    # 4) Bootstrap：组内有放回重采样 → 估计最优周的不确定性
    boot_rows = []
    rng = np.random.default_rng(42) # 固定种子便于复现
    for lab in labels:
        sub = df[df["BMI组"]==lab]
        wk = sub["weeks"].to_numpy()
        if len(wk) == 0:
            continue

        w_stars = []
        for _ in range(N_BOOT):
            idx = rng.integers(0, len(wk), len(wk)) # 与原组等量的有放回抽样
            wk_b = wk[idx]
```

```
            w_star_b, _, _ = find_optimal_week(wk_b)
            w_stars.append(w_star_b)

        w_stars = np.array(w_stars)
        boot_rows.append({
            "BMI组": lab,
            "Bootstrap均值(最优周)": float(np.mean(w_stars)),
            "Bootstrap标准差": float(np.std(w_stars, ddof=1)),
            "CI2.5%(最优周)": float(np.percentile(w_stars, 2.5)),
            "CI97.5%(最优周)": float(np.percentile(w_stars, 97.5)),
            "样本量": int(len(wk)),
            "次数": int(N_BOOT)
        })
    boot_table = pd.DataFrame(boot_rows).sort_values("BMI组").reset_index(drop=True)

    # 5) 保存结果
    os.makedirs(OUT_DIR, exist_ok=True)
    out_base_csv = os.path.join(OUT_DIR, "BMI五分位_基线分组与最优周.csv")
    out_boot_csv = os.path.join(OUT_DIR, "最优周_Bootstrap区间.csv")
    base_table.to_csv(out_base_csv, index=False)
    boot_table.to_csv(out_boot_csv, index=False)

    writer = excel_writer(os.path.join(OUT_DIR, "问题二_最优NIPT_Bootstrap.xlsx"))
    if writer is not None:
        with writer:
            base_table.to_excel(writer, sheet_name="基线最优NIPT", index=False)
            boot_table.to_excel(writer, sheet_name="Bootstrap_CI", index=False)

    # 终端预览（可删）
    print("【基线：各组最优 NIPT】")
    print(base_table[
    ["BMI组",
    "BMI范围",
    "人数",
    "基线最优NIPT周数",
    "基线该周达标概率",
    "基线风险最小值"]
    ].to_string(index=False))
    print("\n【Bootstrap：最优周 95%CI】")
    print(boot_table[
    ["BMI组",
    "Bootstrap均值(最优周)",
    "Bootstrap标准差",
    "CI2.5%(最优周)",
    "CI97.5%(最优周)"]
    ].to_string(index=False))
    print("\nCSV 保存于：", out_base_csv, "与", out_boot_csv)

if __name__ == "__main__":
```

```
    main()
```

附录 E　问题三代码

```
import pandas as pd
import numpy as np

PATH2 = r"G:\25国赛\C题\PythonProject\code3\首次达标孕周数据集.xlsx"
PATH4 = r"G:\25国赛\C题\PythonProject\code3\全量纵向记录表.xlsx"
OUT_DIR = ''

# 超参数设置
THR = 0.040
W_MIN, W_MAX, STEP = 10.0, 25.0, 0.1
C_FAIL, C_DELAY = 1.0, 0.04
QUAL_THRESHOLD = 0.60


def to_weeks(series: pd.Series) -> pd.Series:
    s = pd.to_numeric(series, errors="coerce")
    return s / 7.0 if s.median() > 40 else s


df2 = pd.read_excel(PATH2, sheet_name=0).copy()
df2 = df2.rename(columns={
    "年龄": "age", "检测孕期": "ga", "孕妇BMI": "bmi",
    "原始读段数": "reads", "Y染色体浓度": "yfrac", "怀孕次数": "grav"
})
df2["ga_weeks"] = to_weeks(df2["ga"])
df2 = df2.dropna(subset=["bmi", "ga_weeks"]).reset_index(drop=True)

labels = [f"Q{i}" for i in range(1, 6)]
df2["bmi_group"], bmi_bins = pd.qcut(df2["bmi"], q=5, labels=labels, retbins=True,
     duplicates="drop")

week_grid = np.round(np.arange(W_MIN, W_MAX + 1e-9, STEP), 2)


def empirical_success_prob(weeks_array: np.ndarray, w: float) -> float:
    if len(weeks_array) == 0: return np.nan
    return float(np.mean(weeks_array <= w))


def risk_curve_from_weeks(weeks_array: np.ndarray, week_grid: np.ndarray):
    F = np.array([empirical_success_prob(weeks_array, w) for w in week_grid])
    R = C_FAIL * (1.0 - F) + C_DELAY * np.maximum(0.0, week_grid - W_MIN)
    return F, R
```

```
w2_curves = {}
for lab in labels:
    wk = df2.loc[df2["bmi_group"] == lab, "ga_weeks"].to_numpy()
    F2, R2 = risk_curve_from_weeks(wk, week_grid)
    w2_curves[lab] = {"F2": F2, "R2": R2, "n2": len(wk)}

df4 = pd.read_excel(PATH4, sheet_name=0).copy()
df4 = df4.rename(columns={
    "孕妇代码": "pid", "年龄": "age", "检测孕期": "ga", "孕妇BMI": "bmi",
    "原始读段数": "reads", "Y染色体浓度": "yfrac", "怀孕次数": "grav"
})
df4["ga_weeks"] = to_weeks(df4["ga"])
df4["yfrac"] = pd.to_numeric(df4["yfrac"], errors="coerce")
df4["bmi"] = pd.to_numeric(df4["bmi"], errors="coerce")
edges = bmi_bins.copy()
edges[0] -= 1e-6;
edges[-1] += 1e-6
df4["bmi_group"] = pd.cut(df4["bmi"], bins=edges, labels=labels, include_lowest=True)
df4v = df4.dropna(subset=["ga_weeks", "yfrac", "bmi_group"]).copy()

w4_curves = {}
for lab in labels:
    sub = df4v[df4v["bmi_group"] == lab]
    n_rec = len(sub)
    if n_rec == 0:
        w4_curves[lab] = {"P4": np.full_like(week_grid, np.nan, dtype=float), "n4": 0}
        continue
    ga_arr = sub["ga_weeks"].to_numpy();
    y_arr = sub["yfrac"].to_numpy()
    P4 = np.array([np.mean((ga_arr <= w) & (y_arr >= THR)) for w in week_grid], dtype=float)
    w4_curves[lab] = {"P4": P4, "n4": n_rec}

rows_final = []
for i, lab in enumerate(labels):
    F2 = w2_curves[lab]["F2"];
    R2 = w2_curves[lab]["R2"];
    P4 = w4_curves[lab]["P4"]
    n2 = w2_curves[lab]["n2"];
    n4 = w4_curves[lab]["n4"]
    ok = (P4 >= QUAL_THRESHOLD)
    if not np.any(ok):
        rows_final.append({"BMI组": lab, "工作簿2_样本数": n2, "工作簿4_记录数": n4,
                           "合格阈值(记录级)": QUAL_THRESHOLD, "是否有合格周": "否",
                           "合格最优周": np.nan, "合格最优周_R2(来自W2)": np.nan,
                           "合格最优周_P4(来自W4_记录级)": np.nan,
                           "BMI组下限": bmi_bins[i], "BMI组上限": bmi_bins[i + 1]})
        continue
```

```
    R2_masked = np.where(ok, R2, np.inf)
    k = int(np.argmin(R2_masked))
    rows_final.append({"BMI组": lab, "工作簿2_样本数": n2, "工作簿4_记录数": n4,
                       "合格阈值(记录级)": QUAL_THRESHOLD, "是否有合格周": "是",
                       "合格最优周": float(week_grid[k]),
                       "合格最优周_R2(来自W2)": float(R2[k]),
                       "合格最优周_P4(来自W4_记录级)": float(P4[k]),
                       "BMI组下限": bmi_bins[i], "BMI组上限": bmi_bins[i + 1]})

final_table = pd.DataFrame(rows_final).sort_values("BMI组").reset_index(drop=True)
out_final = "第三问_step3_合格且风险最低_推荐周_按记录计数_阈值60.csv"
final_table.to_csv(out_final, index=False)

#误差检测

import pandas as pd, numpy as np, os

PATH2 = r"G:\25国赛\C题\PythonProject\code3\首次达标孕周数据集.xlsx"
PATH4 = r"G:\25国赛\C题\PythonProject\code3\全量纵向记录表.xlsx"
OUT_DIR = ""

THR = 0.040
W_MIN, W_MAX, STEP = 10.0, 25.0, 0.1
C_FAIL, C_DELAY = 1.0, 0.04
QUAL_THRESHOLD = 0.60
B = 500

rng = np.random.default_rng(12345)

def to_weeks(series: pd.Series) -> pd.Series:
    s = pd.to_numeric(series, errors="coerce")
    return s/7.0 if s.median() > 40 else s

def empirical_success_prob(weeks_array: np.ndarray, w: float) -> float:
    if len(weeks_array)==0:
        return np.nan
    return float(np.mean(weeks_array <= w))

def risk_curve_from_weeks(weeks_array: np.ndarray, week_grid: np.ndarray):
    F = np.array([empirical_success_prob(weeks_array, w) for w in week_grid])
    R = C_FAIL*(1.0 - F) + C_DELAY*np.maximum(0.0, week_grid - W_MIN)
    return F, R

df2 = pd.read_excel(PATH2, sheet_name=0).copy()
df2 = df2.rename(columns={
    "年龄":"age", "检测孕期":"ga", "孕妇BMI":"bmi",
    "原始读段数":"reads", "Y染色体浓度":"yfrac", "怀孕次数":"grav"
})
df2["ga_weeks"] = to_weeks(df2["ga"])
```

```
df2 = df2.dropna(subset=["bmi","ga_weeks"]).reset_index(drop=True)

labels = [f"Q{i}" for i in range(1,6)]
df2["bmi_group"], bmi_bins = pd.qcut(df2["bmi"], q=5, labels=labels, retbins=True,
    duplicates="drop")
wks_by_group = {lab: df2.loc[df2["bmi_group"]==lab,"ga_weeks"].to_numpy() for lab in labels}

week_grid = np.round(np.arange(W_MIN, W_MAX+1e-9, STEP), 2)


df4 = pd.read_excel(PATH4, sheet_name=0).copy()
df4 = df4.rename(columns={
   "孕妇代码":"pid", "年龄":"age", "检测孕期":"ga", "孕妇BMI":"bmi",
   "原始读段数":"reads", "Y染色体浓度":"yfrac", "怀孕次数":"grav"
})
df4["ga_weeks"] = to_weeks(df4["ga"])
df4["yfrac"] = pd.to_numeric(df4["yfrac"], errors="coerce")
df4["bmi"] = pd.to_numeric(df4["bmi"], errors="coerce")

edges = bmi_bins.copy()
edges[0] = edges[0] - 1e-6
edges[-1] = edges[-1] + 1e-6
df4["bmi_group"] = pd.cut(df4["bmi"], bins=edges, labels=labels, include_lowest=True)
df4v = df4.dropna(subset=["ga_weeks","yfrac","bmi_group"]).copy()

P4_curves = {}
for lab in labels:
   sub = df4v[df4v["bmi_group"]==lab]
   n_rec = len(sub)
   if n_rec==0:
      P4_curves[lab] = {"P4": np.full_like(week_grid, np.nan, dtype=float), "n_rec": 0}
   else:
      ga_arr = sub["ga_weeks"].to_numpy()
      y_arr = sub["yfrac"].to_numpy()
      P4 = np.array([ np.mean((ga_arr <= w) & (y_arr >= THR)) for w in week_grid ], dtype=float)
      P4_curves[lab] = {"P4": P4, "n_rec": n_rec}


boot_records = []
for b in range(1, 500+1):
   for lab in labels:
      wk_orig = wks_by_group[lab]
      n = len(wk_orig)
      if n == 0:
         boot_records.append({"iter": b, "BMI组": lab, "最优周_boot": np.nan})
         continue
      idx = rng.integers(0, n, size=n)
      wk_boot = wk_orig[idx]
      F2, R2 = risk_curve_from_weeks(wk_boot, week_grid)
```

```
        P4 = P4_curves[lab]["P4"]
        ok = (P4 >= QUAL_THRESHOLD)
        if not np.any(ok):
            boot_records.append({"iter": b, "BMI组": lab, "最优周_boot": np.nan})
            continue
        R2_masked = np.where(ok, R2, np.inf)
        k = int(np.argmin(R2_masked))
        boot_records.append({"iter": b, "BMI组": lab, "最优周_boot": float(week_grid[k])})

boot_df = pd.DataFrame(boot_records)

summary_rows = []
for lab in labels:
    sub = boot_df[(boot_df["BMI组"]==lab) & (~boot_df["最优周_boot"].isna())]["最优周_boot"]
    m = sub.mean() if len(sub)>0 else np.nan
    sd = sub.std(ddof=1) if len(sub)>1 else np.nan
    q025 = sub.quantile(0.025) if len(sub)>0 else np.nan
    q500 = sub.quantile(0.500) if len(sub)>0 else np.nan
    q975 = sub.quantile(0.975) if len(sub)>0 else np.nan
    summary_rows.append({
        "BMI组": lab,
        "有效自助迭代数": int(sub.shape[0]),
        "最优周_均值": float(m) if not np.isnan(m) else np.nan,
        "最优周_标准差": float(sd) if not np.isnan(sd) else np.nan,
        "最优周_p2.5": float(q025) if not np.isnan(q025) else np.nan,
        "最优周_中位数": float(q500) if not np.isnan(q500) else np.nan,
        "最优周_p97.5": float(q975) if not np.isnan(q975) else np.nan
    })
summary_df = pd.DataFrame(summary_rows).sort_values("BMI组").reset_index(drop=True)

os.makedirs(OUT_DIR, exist_ok=True)
out_boot = "第三问_step3_bootstrap_最优周分布_阈值60.csv"
out_sum = "第三问_step3_bootstrap_最优周汇总_阈值60.csv"
boot_df.to_csv(out_boot, index=False)
summary_df.to_csv(out_sum, index=False)

summary_df.head(10), out_sum, out_boot
```

附录 F　问题四代码

```
import pandas as pd, numpy as np
import statsmodels.api as sm
from scipy import stats

# 读取
df = pd.read_excel(r"G:\25国赛\C题\PythonProject\code4\筛.xlsx")
```

```
y_col = "abnormal"
x_cols = ["年龄","检测孕周","GC含量","原始读段数","在参考基因组上比对的比例",
         "13号染色体的Z值","18号染色体的Z值","21号染色体的Z值","X染色体的Z值",
         "X染色体浓度","13号染色体的GC含量","18号染色体的GC含量","21号染色体的GC含量"]

# 选取并转数值、去缺失
df_use = df[[y_col] + x_cols].copy()
for c in df_use.columns:
    df_use[c] = pd.to_numeric(df_use[c], errors="coerce")
df_use = df_use.dropna().reset_index(drop=True)

X = sm.add_constant(df_use[x_cols])
y = df_use[y_col]
model = sm.Logit(y, X)
res = model.fit(disp=False)



df_use["p_hat"] = res.predict(X)

# Hosmer-Lemeshow检验（按预测概率分位分组）
def hosmer_lemeshow(y_true, p_pred, g=10):
    data = pd.DataFrame({"y": y_true, "p": p_pred}).sort_values("p")
    data["group"] = pd.qcut(data["p"], q=g, duplicates="drop")
    tab = data.groupby("group").agg(n=("y","size"),
                                    y_obs=("y","sum"),
                                    p_bar=("p","mean")).reset_index()
    tab["y_exp"] = tab["n"]*tab["p_bar"]
    chi2 = np.sum((tab["y_obs"] - tab["y_exp"])**2 /
                  (tab["n"]*tab["p_bar"]*(1-tab["p_bar"]) + 1e-12))
    dof = tab.shape[0] - 2
    pval = 1 - stats.chi2.cdf(chi2, dof)
    return tab, chi2, dof, pval

hl_table, hl_chi2, hl_df, hl_p = hosmer_lemeshow(y, df_use["p_hat"], g=10)

params = res.params
conf = res.conf_int()
or_table = pd.DataFrame({
    "变量": params.index,
    "系数": params.values,
    "OR(=exp(系数))": np.exp(params.values),
    "CI下限(OR)": np.exp(conf[0].values),
    "CI上限(OR)": np.exp(conf[1].values),
    "p值": res.pvalues.values
})

# 概率计算方程（logit → 概率）
eq_terms = [f"{coef:.6f}*{name}" for name, coef in params.items() if name!="const"]
```

```
equation = f"线性预测  = {params['const']:.6f} + " + " + ".join(eq_terms) + \
          "\n概率 p = 1 / (1 + exp(- ))"

# 保存结果
or_path = "Logit_OR表.csv"
hl_path = "HL检验分组表.csv"
sum_path = "Logit_摘要.txt"
or_table.to_csv(or_path, index=False)
hl_table.to_csv(hl_path, index=False)
with open(sum_path, "w", encoding="utf-8") as f:
    f.write(res.summary2().as_text())
    f.write("\n\n--- 概率计算方程 ---\n")
    f.write(equation)
    f.write(f"\n\n--- Hosmer-Lemeshow 检验 ---\nChi2 = {hl_chi2:.3f}, df = {hl_df}, p =
        {hl_p:.4f}\n")
    f.write("解释: 当 p 不显著(>0.05) → 拟合效果较好; 当 p 显著( 0.05) → 拟合较差。\n")
```